

细节推导：Kalman 增益如何从创新里长出来

2026 年 3 月 29 日

1 目标

这一份细节推导只解决一件事：

既然更新结构已经定成

$$\hat{\mathbf{x}}_{t|t} = \hat{\mathbf{x}}_{t|t-1} + \mathbf{K}_t \tilde{\mathbf{y}}_t,$$

那么 $\mathbf{K}_t$ 为什么会等于

$$\mathbf{P}_{t|t-1} \mathbf{H}^\top \mathbf{S}_t^{-1}?$$

核心思路不是先写 Joseph 形式，而是顺着下面这条链走：

1. 先看创新 $\tilde{\mathbf{y}}_t$ 里到底混了什么；
2. 再定义创新自己的不确定性 $\mathbf{S}_t$ ；
3. 再看状态误差和创新的互协方差；
4. 最后用“更新后误差不该再和创新相关”这一条朴素要求，把 $\mathbf{K}_t$ 解出来。

2 第一步：创新并不等于真相，它是两部分的混合

enter 从创新定义开始：

$$\tilde{\mathbf{y}}_t = \mathbf{y}_t - \hat{\mathbf{y}}_{t|t-1}.$$

rw 代入观测方程 $\mathbf{y}_t = \mathbf{H}\mathbf{x}_t + \mathbf{v}_t$ 和预测观测 $\hat{\mathbf{y}}_{t|t-1} = \mathbf{H}\hat{\mathbf{x}}_{t|t-1}$ ：

$$\tilde{\mathbf{y}}_t = \mathbf{H}\mathbf{x}_t + \mathbf{v}_t - \mathbf{H}\hat{\mathbf{x}}_{t|t-1}.$$

rw 把 $\mathbf{x}_t - \hat{\mathbf{x}}_{t|t-1}$ 认成预测误差 $\mathbf{e}_{t|t-1}$ ：

$$\tilde{\mathbf{y}}_t = \mathbf{H}\mathbf{e}_{t|t-1} + \mathbf{v}_t.$$

done 所以创新不是“完整的状态误差”，而是“传感器能看见的那部分状态误差”再混上“这一拍的测量噪声”。例如 $H = [1 \ 0]$ 时，传感器只直接看见位置误差，看不见速度误差。

3 第二步：先算创新自己的协方差 S_t

enter 定义创新协方差：

$$S_t = \mathbb{E}[\tilde{\mathbf{y}}_t \tilde{\mathbf{y}}_t^\top].$$

rw 把 $\tilde{\mathbf{y}}_t = H\mathbf{e}_{t|t-1} + \mathbf{v}_t$ 代进去：

$$S_t = \mathbb{E}[(H\mathbf{e}_{t|t-1} + \mathbf{v}_t)(H\mathbf{e}_{t|t-1} + \mathbf{v}_t)^\top].$$

rw 按 $(a+b)(a+b)^\top$ 展开：

$$\begin{aligned} S_t &= \mathbb{E}[H\mathbf{e}_{t|t-1}\mathbf{e}_{t|t-1}^\top H^\top] \\ &\quad + \mathbb{E}[H\mathbf{e}_{t|t-1}\mathbf{v}_t^\top] \\ &\quad + \mathbb{E}[\mathbf{v}_t\mathbf{e}_{t|t-1}^\top H^\top] \\ &\quad + \mathbb{E}[\mathbf{v}_t\mathbf{v}_t^\top]. \end{aligned}$$

have 默认预测误差 $\mathbf{e}_{t|t-1}$ 和当前测量噪声 $\mathbf{v}_t$ 独立，而且 $\mathbb{E}[\mathbf{v}_t] = \mathbf{0}$ ，所以中间两个交叉项为 0。

rw 再用

$$\mathbb{E}[\mathbf{e}_{t|t-1}\mathbf{e}_{t|t-1}^\top] = P_{t|t-1}, \quad \mathbb{E}[\mathbf{v}_t\mathbf{v}_t^\top] = R,$$

就得到：

$$S_t = HP_{t|t-1}H^\top + R.$$

done 所以 S_t 衡量的是“这一拍创新本身有多不确定”，而不是“状态有多不确定”。

4 第三步：再算状态误差和创新的互协方差

enter 我们关心的是

$$\mathbb{E}[\mathbf{e}_{t|t-1}\tilde{\mathbf{y}}_t^\top].$$

rw 把 $\tilde{\mathbf{y}}_t = H\mathbf{e}_{t|t-1} + \mathbf{v}_t$ 代进去：

$$\mathbb{E}[\mathbf{e}_{t|t-1}\tilde{\mathbf{y}}_t^\top] = \mathbb{E}[\mathbf{e}_{t|t-1}(H\mathbf{e}_{t|t-1} + \mathbf{v}_t)^\top].$$

rw 展开：

$$\mathbb{E}[\mathbf{e}_{t|t-1}\tilde{\mathbf{y}}_t^\top] = \mathbb{E}[\mathbf{e}_{t|t-1}\mathbf{e}_{t|t-1}^\top]\mathbf{H}^\top + \mathbb{E}[\mathbf{e}_{t|t-1}\mathbf{v}_t^\top].$$

rw 第二项依然因为独立和零均值而为 0，于是

$$\mathbb{E}[\mathbf{e}_{t|t-1}\tilde{\mathbf{y}}_t^\top] = \mathbf{P}_{t|t-1}\mathbf{H}^\top.$$

done 这条式子在直觉上很重要：如果某个状态方向和创新根本不相关，那创新就没有理由去修它。

5 第四步：直接把目标函数写出来，对 $\mathbf{K}_t$ 求最小值

enter 更新结构已经固定成

$$\hat{\mathbf{x}}_{t|t} = \hat{\mathbf{x}}_{t|t-1} + \mathbf{K}_t\tilde{\mathbf{y}}_t.$$

rw 所以更新后误差就是

$$\mathbf{e}_{t|t} = \mathbf{x}_t - \hat{\mathbf{x}}_{t|t} = \mathbf{e}_{t|t-1} - \mathbf{K}_t\tilde{\mathbf{y}}_t.$$

have 先说朴素想法。既然创新 $\tilde{\mathbf{y}}_t$ 已经被拿来修正过一次，那么修完之后的误差里，就不该还残留和这份创新同方向的、可继续利用的信息。

rw 但这句话本身还只是直觉。严格证明时，还是应该回到最优化问题本身：直接把目标函数写出来，对 $\mathbf{K}_t$ 求最小值。

$$J(\mathbf{K}_t) = \mathbb{E}[\|\mathbf{e}_{t|t}\|_2^2] = \text{tr}(\mathbf{P}_{t|t}).$$

rw 这里最后一个等号来自协方差定义。因为

$$\|\mathbf{e}_{t|t}\|_2^2 = \mathbf{e}_{t|t}^\top \mathbf{e}_{t|t} = \text{tr}(\mathbf{e}_{t|t}\mathbf{e}_{t|t}^\top),$$

rw 再利用“期望和迹可以交换”，就有

$$\mathbb{E}[\|\mathbf{e}_{t|t}\|_2^2] = \text{tr}\left(\mathbb{E}[\mathbf{e}_{t|t}\mathbf{e}_{t|t}^\top]\right) = \text{tr}(\mathbf{P}_{t|t}).$$

rw 如果你还想追问“为什么迹和期望可以交换”，那就把它写成分量和：设 $\mathbf{A} = (A_{ij})$ ，则

$$\text{tr}(\mathbb{E}[\mathbf{A}]) = \sum_i \mathbb{E}[A_{ii}] = \mathbb{E}\left[\sum_i A_{ii}\right] = \mathbb{E}[\text{tr}(\mathbf{A})].$$

rw 这里中间那一步

$$\sum_i \mathbb{E}[A_{ii}] = \mathbb{E}\left[\sum_i A_{ii}\right]$$

rw 用的只是期望的线性性：

$$\mathbb{E}[X_1 + \cdots + X_n] = \mathbb{E}[X_1] + \cdots + \mathbb{E}[X_n].$$

done 所以这里本质上只是把有限项求和靠期望的线性性移进移出。

rw 把 $\mathbf{e}_{t|t} = \mathbf{e}_{t|t-1} - \mathbf{K}_t \tilde{\mathbf{y}}_t$ 直接代进去：

$$J(\mathbf{K}_t) = \text{tr}\left(\mathbb{E}[(\mathbf{e}_{t|t-1} - \mathbf{K}_t \tilde{\mathbf{y}}_t)(\mathbf{e}_{t|t-1} - \mathbf{K}_t \tilde{\mathbf{y}}_t)^\top]\right).$$

rw 先把括号展开：

$$\begin{aligned} J(\mathbf{K}_t) &= \text{tr}\left(\mathbb{E}[\mathbf{e}_{t|t-1} \mathbf{e}_{t|t-1}^\top]\right) \\ &\quad - \text{tr}\left(\mathbb{E}[\mathbf{e}_{t|t-1} \tilde{\mathbf{y}}_t^\top] \mathbf{K}_t^\top\right) \\ &\quad - \text{tr}\left(\mathbf{K}_t \mathbb{E}[\tilde{\mathbf{y}}_t \mathbf{e}_{t|t-1}^\top]\right) \\ &\quad + \text{tr}\left(\mathbf{K}_t \mathbb{E}[\tilde{\mathbf{y}}_t \tilde{\mathbf{y}}_t^\top] \mathbf{K}_t^\top\right). \end{aligned}$$

rw 再把前面已经算出来的两个量代入：

$$\mathbb{E}[\mathbf{e}_{t|t-1} \mathbf{e}_{t|t-1}^\top] = \mathbf{P}_{t|t-1}, \quad \mathbb{E}[\mathbf{e}_{t|t-1} \tilde{\mathbf{y}}_t^\top] = \mathbf{P}_{t|t-1} \mathbf{H}^\top, \quad \mathbb{E}[\tilde{\mathbf{y}}_t \tilde{\mathbf{y}}_t^\top] = \mathbf{S}_t.$$

rw 于是目标函数变成一个显式的二次型：

$$\begin{aligned} J(\mathbf{K}_t) &= \text{tr}(\mathbf{P}_{t|t-1}) - \text{tr}(\mathbf{P}_{t|t-1} \mathbf{H}^\top \mathbf{K}_t^\top) \\ &\quad - \text{tr}(\mathbf{K}_t \mathbf{H} \mathbf{P}_{t|t-1}) + \text{tr}(\mathbf{K}_t \mathbf{S}_t \mathbf{K}_t^\top). \end{aligned}$$

rw 由于 $\text{tr}(\mathbf{P}_{t|t-1} \mathbf{H}^\top \mathbf{K}_t^\top) = \text{tr}(\mathbf{K}_t \mathbf{H} \mathbf{P}_{t|t-1})$ ，前两项可以合并：

$$\begin{aligned} J(\mathbf{K}_t) &= \text{tr}(\mathbf{P}_{t|t-1}) - 2 \text{tr}(\mathbf{K}_t \mathbf{H} \mathbf{P}_{t|t-1}) \\ &\quad + \text{tr}(\mathbf{K}_t \mathbf{S}_t \mathbf{K}_t^\top). \end{aligned}$$

rw 现在直接对 $\mathbf{K}_t$ 求导。用到两条标准公式：

$$\frac{\partial}{\partial \mathbf{K}} \text{tr}(\mathbf{K} \mathbf{A}) = \mathbf{A}^\top, \quad \frac{\partial}{\partial \mathbf{K}} \text{tr}(\mathbf{K} \mathbf{S} \mathbf{K}^\top) = 2 \mathbf{K} \mathbf{S} \quad (\mathbf{S} = \mathbf{S}^\top).$$

rw 因此

$$\frac{\partial J}{\partial \mathbf{K}_t} = -2\mathbf{P}_{t|t-1}\mathbf{H}^\top + 2\mathbf{K}_t\mathbf{S}_t.$$

done 令导数为 0，就得到

$$\mathbf{K}_t = \mathbf{P}_{t|t-1}\mathbf{H}^\top \mathbf{S}_t^{-1}.$$

6 一句话理解这条公式

$$\mathbf{K}_t = \underbrace{\mathbf{P}_{t|t-1}\mathbf{H}^\top}_{\text{创新对状态误差有多有用}} \underbrace{\mathbf{S}_t^{-1}}_{\text{创新自己有多可靠}}$$

它其实就是多维版的“线性回归系数”。一维时更明显：

$$K_t = \frac{\text{Cov}(e_{t|t-1}, \tilde{y}_t)}{\text{Var}(\tilde{y}_t)}.$$

所以 Kalman 增益不是神秘公式，而是在回答：

这次残差到底有多值得信，以及该把它分配到哪些状态方向上。

7 工程尾注：如果还要更新协方差

have 思想上，前面的推导已经够了。

rw 如果实现里还要更新后验协方差，一个常用的数值稳定写法是

$$\mathbf{P}_{t|t} = (\mathbf{I} - \mathbf{K}_t\mathbf{H})\mathbf{P}_{t|t-1}(\mathbf{I} - \mathbf{K}_t\mathbf{H})^\top + \mathbf{K}_t\mathbf{R}\mathbf{K}_t^\top.$$

done 这叫 Joseph 形式。它的角色主要是工程稳健性，不是理解 $\mathbf{K}_t$ 公式来龙去脉的主线。