

细节推导：为什么更新结构长成 $\hat{\mathbf{x}}_{t|t} = \hat{\mathbf{x}}_{t|t-1} + \mathbf{K}_t \tilde{\mathbf{y}}_t$

2026 年 3 月 29 日

1 目标

我们想解释的不是一个“背下来的公式”，而是下面这条更新结构为什么几乎是被问题本身逼出来的：

$$\hat{\mathbf{x}}_{t|t} = \hat{\mathbf{x}}_{t|t-1} + \mathbf{K}_t \tilde{\mathbf{y}}_t, \quad \tilde{\mathbf{y}}_t = \mathbf{y}_t - \hat{\mathbf{y}}_{t|t-1}.$$

2 先明确我们手里到底有什么

在更新这一步开始时，手里已经有两样东西：

1. 预测状态 $\hat{\mathbf{x}}_{t|t-1}$ ；
2. 新观测带来的残差信息 $\tilde{\mathbf{y}}_t$ 。

所以更新后的估计，本质上只能写成某个函数：

$$\hat{\mathbf{x}}_{t|t} = \Phi(\hat{\mathbf{x}}_{t|t-1}, \mathbf{y}_t).$$

3 为什么要先把观测变成创新

rw 观测值 $\mathbf{y}_t$ 本身没有告诉你“这次到底新增了多少信息”。真正有用的是它和预测观测的差。

所以先定义

$$\hat{\mathbf{y}}_{t|t-1}, \quad \tilde{\mathbf{y}}_t = \mathbf{y}_t - \hat{\mathbf{y}}_{t|t-1},$$

再注意一个对新手很重要的点：到了时刻 t 的更新阶段， $\hat{\mathbf{x}}_{t|t-1}$ 已经是上一步算好的结果，所以 $\hat{\mathbf{y}}_{t|t-1}$ 也是已知量。

于是对这一拍来说， $\mathbf{y}_t$ 和 $\tilde{\mathbf{y}}_t$ 是一一对应的：

$$\tilde{\mathbf{y}}_t = \mathbf{y}_t - \hat{\mathbf{y}}_{t|t-1}, \quad \mathbf{y}_t = \tilde{\mathbf{y}}_t + \hat{\mathbf{y}}_{t|t-1}.$$

rw 所以把更新公式写成依赖 $\mathbf{y}_t$ 还是依赖 $\tilde{\mathbf{y}}_t$ ，并不会丢信息。只是创新更直接暴露了“观测相对预测新增了什么”。

因此再把更新公式改写成

$$\hat{\mathbf{x}}_{t|t} = \Psi(\hat{\mathbf{x}}_{t|t-1}, \tilde{\mathbf{y}}_t).$$

4 为什么修正项要依赖创新

rw 如果观测和预测完全一致，也就是 $\tilde{\mathbf{y}}_t = \mathbf{0}$ ，那更新后就不应该乱动。所以更新后的估计至少要满足：

$$\tilde{\mathbf{y}}_t = \mathbf{0} \implies \hat{\mathbf{x}}_{t|t} = \hat{\mathbf{x}}_{t|t-1}.$$

rw 反过来，如果残差越大，说明观测提供的新信息越强，修正幅度也应该越大。这会把我们逼到一种更具体的形式：

$$\hat{\mathbf{x}}_{t|t} = \hat{\mathbf{x}}_{t|t-1} + \mathbf{c}_t, \quad \mathbf{c}_t = g(\tilde{\mathbf{y}}_t), \quad g(\mathbf{0}) = \mathbf{0}.$$

5 为什么又进一步写成线性形式

rw 到这里为止，我们已经知道更新律可以看成“创新进去，更新后估计出来”的函数。由于在时刻 t ， $\hat{\mathbf{x}}_{t|t-1}$ 已经是已知量，所以可以把它吸收到函数记号里，写成

$$\hat{\mathbf{x}}_{t|t} = \varphi_t(\tilde{\mathbf{y}}_t).$$

have 而上一步已经给出一个关键边界条件：如果创新为 0，就不该改口。也就是说

$$\varphi_t(\mathbf{0}) = \hat{\mathbf{x}}_{t|t-1}.$$

rw 现在在 $\tilde{\mathbf{y}}_t = \mathbf{0}$ 附近，对这个更新律做一阶线性展开：

$$\varphi_t(\tilde{\mathbf{y}}_t) \approx \varphi_t(\mathbf{0}) + \left. \frac{\partial \varphi_t}{\partial \tilde{\mathbf{y}}} \right|_{\tilde{\mathbf{y}}=\mathbf{0}} \tilde{\mathbf{y}}_t.$$

rw 把 $\varphi_t(\mathbf{0}) = \hat{\mathbf{x}}_{t|t-1}$ 代回去，再把这个一阶导矩阵记作 $\mathbf{G}_t$ ，就得到

$$\hat{\mathbf{x}}_{t|t} \approx \hat{\mathbf{x}}_{t|t-1} + \mathbf{G}_t \tilde{\mathbf{y}}_t.$$

rw 现在才把这个待定线性映射 $\mathbf{G}_t$ 记作 $\mathbf{K}_t$ 。

$$\hat{\mathbf{x}}_{t|t} = \hat{\mathbf{x}}_{t|t-1} + \mathbf{K}_t \tilde{\mathbf{y}}_t.$$

done 这个视角和 EKF 很一致：都是先承认“真实更新律可能更一般”，再抓它在当前点附近最重要的一阶线性部分。区别只在于 KF 最后还能进一步证明：最优更新本来就落在线性族里。

6 K_t 到底是什么

have 先看维度。若状态是 $\mathbf{x}_t \in \mathbb{R}^n$ ，观测是 $\mathbf{y}_t \in \mathbb{R}^m$ ，那么创新也在 $\mathbb{R}^m$ 里。为了让 $\mathbf{K}_t \tilde{\mathbf{y}}_t$ 能加回 $\hat{\mathbf{x}}_{t|t-1}$ ， $\mathbf{K}_t$ 必须是

$$\mathbf{K}_t \in \mathbb{R}^{n \times m}.$$

rw 这说明 $\mathbf{K}_t$ 不是“一个比例”，而是一个矩阵。它负责把观测空间里的误差，翻译成状态空间里的修正。

$\mathbf{K}_t$ 的每一列，都表示“某一维观测残差应该如何分摊到各个状态维度上”。

7 放到小车例子看

在主文档的小车例子中，

$$\mathbf{x}_t = \begin{bmatrix} p_t \\ v_t \end{bmatrix} \in \mathbb{R}^2, \quad y_t \in \mathbb{R}.$$

因为只测位置，观测维度是 1，所以

$$\mathbf{K}_t = \begin{bmatrix} k_p \\ k_v \end{bmatrix} \in \mathbb{R}^{2 \times 1}.$$

rw 把它代回更新式，得到两条最有解释力的标量式：

$$\hat{p}_{t|t} = \hat{p}_{t|t-1} + k_p \tilde{y}_t, \quad \hat{v}_{t|t} = \hat{v}_{t|t-1} + k_v \tilde{y}_t.$$

done 这两条式子揭示了 $\mathbf{K}_t$ 最值得记住的含义：虽然传感器只直接看到了位置，但同一个位置残差，仍然可以顺带修正速度。

8 再往前走一步：为什么不是别的复杂函数

当然，你也可以幻想更新式写成更复杂的样子，比如：

$$\hat{\mathbf{x}}_{t|t} = \hat{\mathbf{x}}_{t|t-1} + g(\tilde{\mathbf{y}}_t),$$

其中 g 是非线性的。

但在线性高斯世界里，这样做没有必要：

1. 问题本身是线性的；
2. 最优估计会落在线性更新族里；
3. 真正难的不是更新结构，而是**这个线性映射 K_t 该取多大**。

所以 4.3 的核心不是“把结构想复杂”，而是认清：

更新结构先天就该长成“旧预测 + 增益乘创新”。

下一步真正要解决的问题，才是怎么选出最优的 K_t 。