

强化学习中的卡尔曼滤波基础笔记

从含噪观测到基于信念的决策

2026 年 3 月 30 日

目录

1	为什么要把二者放在一起	2
2	贯穿全文的例子	2
3	高层逻辑	3
3.1	黑盒视角	3
3.2	为什么滤波能帮助策略	3
4	卡尔曼滤波这一侧	4
4.1	预测与校正	4
4.2	直觉理解	4
5	强化学习这一侧	4
5.1	策略真正看到什么	4
5.2	回报仍然由强化学习定义	5
6	二者如何耦合	5
6.1	模式一：先滤波，再决策	5
6.2	模式二：先学模型，再做滤波	5
6.3	模式三：利用协方差做探索或风险控制	5
7	一个具体数值例子	6
7.1	第一步：预测	6
7.2	第二步：观测	6
7.3	第三步：校正	6
7.4	第四步：决策	7
8	它究竟带来了什么	7

1 为什么要把二者放在一起	2
9 它并不能神奇解决什么	7
9.1 线性与高斯假设	7
9.2 模型误差	7
9.3 回报设计并不会自动变简单	7
10 一个最小设计原则	8
11 最后的观点	8

1 为什么要把二者放在一起

强化学习常被讲述为这样一件事：智能体看见环境，采取动作，再从回报中改进策略。然而真实系统并不如此理想。机器人通过含噪传感器感知世界，交易系统只能看到价格而看不到潜在市场状态，无线控制器接收到的信道信息也往往存在延迟与扰动。在这些场景中，智能体真正面对的并不是清晰的状态，而是不完整的证据。

卡尔曼滤波的价值恰恰出现在这里。它并不取代强化学习，而是在决策之前，先对隐藏状态做出有纪律的估计。强化学习回答的问题是“下一步应当做什么？”卡尔曼滤波回答的是更靠前的那个问题“此刻最可能正在发生什么？”

因此，二者的结合是自然的：

- 卡尔曼滤波降低状态估计中的不确定性；
- 强化学习利用估计后的状态去优化长期回报；
- 二者合在一起，便能将含噪测量转化为更稳定的序贯决策。

其核心优点在于结构清晰：一个模块负责估计，另一个模块负责决策。真正的工程难点，在于如何让二者的假设彼此兼容。

2 贯穿全文的例子

考虑一台沿直走廊移动的小型地面机器人。在时刻 t ，其真实状态记为

$$x_t = \begin{bmatrix} p_t \\ v_t \end{bmatrix},$$

其中 p_t 表示位置， v_t 表示速度。

机器人选择加速度指令 a_t 。其运动可近似写为

$$x_{t+1} = Ax_t + Ba_t + w_t,$$

其中 w_t 是过程噪声。摄像头并不能直接给出完整状态，它只返回带噪的位置测量：

$$y_t = Cx_t + r_t,$$

其中 r_t 是测量噪声。

设机器人当前位于走廊中央附近。摄像头报告

$$y_t = 10.4 \text{ 米},$$

但真实位置并不直接可知。机器人必须决定是继续加速、刹车，还是保持当前趋势。若它直接对原始测量作出反应，控制很容易来回摆动；若它先估计潜在状态，再做动作，行为就会显著稳定。

这台走廊机器人，将作为全文的统一例子。

3 高层逻辑

3.1 黑盒视角

整个组合系统可以理解为四个连续阶段：

1. 环境产生隐藏状态 x_t ；
2. 传感器产生含噪观测 y_t ；
3. 卡尔曼滤波器利用历史信息与新观测，形成估计 $\hat{x}_{t|t}$ ；
4. 强化学习策略根据该估计选择动作 a_t 。

动作施加之后，环境继续演化，回报被揭示，随后进入下一轮循环。

应当注意，滤波器的输入并不只是当前传感器读数。它还利用上一步的估计与已知控制动作。因此它的输出，不是单纯的“平滑测量值”，而是一个与系统动力学一致的状态信念。

3.2 为什么滤波能帮助策略

当输入表示本身不稳定时，强化学习会变得困难。若两个几乎相同的物理情形，却对应到差异很大的原始观测，那么策略便不得不额外学习如何对噪声做平均。卡尔曼滤波主要从三方面缓解这一问题：

- 它把预测与测量结合起来，从而平滑传感器噪声；
- 它能够重构速度、偏置等并未被直接观测的潜变量；
- 它通过协方差显式暴露不确定性，这对风险敏感控制或探索都很重要。

简言之，滤波器提供给策略的对象，比原始传感器流更接近“可用于推理的状态”。

4 卡尔曼滤波这一侧

4.1 预测与校正

在线性高斯情形下，卡尔曼滤波在“预测”和“校正”之间交替进行。

预测。 利用上一步估计与已采取的动作，对下一时刻状态作出预报：

$$\hat{x}_{t|t-1} = A\hat{x}_{t-1|t-1} + Ba_{t-1}.$$

与此同时，不确定性也随之向前传播。

校正。 将真实测量 y_t 与预测测量 $C\hat{x}_{t|t-1}$ 相比较，二者之差称为创新。若创新很小，说明模型和新数据大体一致；若创新很大，说明估计应当向传感器读数靠拢。

卡尔曼增益决定校正幅度。传感器越可靠，校正越积极；传感器越嘈杂，校正越保守。

4.2 直觉理解

人们常说卡尔曼滤波是“最优融合规则”，但这一表述略显抽象。更直白的理解是：

预测器说明：若模型可信，系统此刻应在哪里。传感器说明：若测量可信，系统看起来在哪里。滤波器则在二者之间给出有原则的折中。

对于走廊机器人，若模型预测位置为 10.0 米，而摄像头报告 10.4 米，那么：

- 若摄像头很嘈杂，校正后的位置也许只会移动到 10.1；
- 若摄像头很精确，校正后的位置也许会接近 10.35。

估计会改变，但不是机械地照搬传感器读数。

5 强化学习这一侧

5.1 策略真正看到什么

在标准强化学习中，策略把状态映射到动作：

$$a_t \sim \pi(\cdot \mid s_t).$$

若真实状态并不能直接观测，一种自然替代是把估计状态输入给策略：

$$a_t \sim \pi(\cdot \mid \hat{x}_{t|t}).$$

这不只是实现细节上的替换，而是对问题表述本身的修正：智能体不再是“根据原始观测行动”，而是“根据对隐藏状态的信念行动”。只要环境具有部分可观测性，这种看法就是更准确的。

5.2 回报仍然由强化学习定义

滤波器负责估计状态，但并不决定什么是“好行为”。这一任务属于回报设计。对机器人而言，回报项可以包括：

- 鼓励向目标位置推进；
- 惩罚过大的加速度；
- 惩罚碰撞或偏离走廊。

随后，策略在滤波后的状态估计上学习如何最大化累计回报，而不是在原始测量上直接学习。

6 二者如何耦合

6.1 模式一：先滤波，再决策

这是最基础、也最常见的结构：

1. 用卡尔曼滤波器根据动作与观测估计隐藏状态；
2. 将该估计输入策略或价值函数；
3. 按常规方式训练强化学习智能体。

当系统动力学近似线性、主要困难来自传感器噪声时，这一方案尤其合理。

6.2 模式二：先学模型，再做滤波

在许多应用中，矩阵 A 、 B 、 C 并不完全已知。此时可以先从数据中学习近似动力学模型，再在该模型上叠加卡尔曼风格的估计器。这一思想常见于模型式强化学习与潜状态世界模型中。

它的优点是具有适应性；它的风险则是模型失配。若学习到的模型质量很差，那么建立其上的滤波器可能会“带着很高信心地出错”。

6.3 模式三：利用协方差做探索或风险控制

协方差矩阵不仅描述误差大小，也提供了不确定性的量化摘要。智能体至少可以通过两种方式利用它：

- 当状态估计不可靠时，更谨慎地探索；
- 当不确定性较大时，选择更稳健的动作。

正是在这里，卡尔曼滤波的贡献超出了简单去噪。它提供的是一种“对自己无知程度的量化”。

7 一个具体数值例子

设时间步长为 1 秒，运动模型取为

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}, \quad B = \begin{bmatrix} 0.5 \\ 1 \end{bmatrix}, \quad C = \begin{bmatrix} 1 & 0 \end{bmatrix}.$$

假设上一步更新后，智能体相信

$$\hat{x}_{t-1|t-1} = \begin{bmatrix} 8.0 \\ 1.0 \end{bmatrix}.$$

此时它选择加速度

$$a_{t-1} = 0.2.$$

7.1 第一步：预测

预测状态为

$$\hat{x}_{t|t-1} = A\hat{x}_{t-1|t-1} + Ba_{t-1} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 8.0 \\ 1.0 \end{bmatrix} + \begin{bmatrix} 0.5 \\ 1 \end{bmatrix} (0.2) = \begin{bmatrix} 9.1 \\ 1.2 \end{bmatrix}.$$

这意味着，在尚未看到新的摄像头画面之前，机器人预测自己已经移动到位置 9.1，速度约为 1.2。

7.2 第二步：观测

摄像头报告

$$y_t = 9.7.$$

于是创新为

$$y_t - C\hat{x}_{t|t-1} = 9.7 - 9.1 = 0.6.$$

7.3 第三步：校正

设此刻的卡尔曼增益为

$$K_t = \begin{bmatrix} 0.6 \\ 0.2 \end{bmatrix}.$$

则更新后的估计为

$$\hat{x}_{t|t} = \hat{x}_{t|t-1} + K_t(0.6) = \begin{bmatrix} 9.1 \\ 1.2 \end{bmatrix} + \begin{bmatrix} 0.36 \\ 0.12 \end{bmatrix} = \begin{bmatrix} 9.46 \\ 1.32 \end{bmatrix}.$$

这一步已经展示了其价值：观测只直接提供了位置，但由于动力学模型把位置与速度联系在一起，滤波器同时修正了速度估计。

7.4 第四步：决策

强化学习策略此时收到的输入是滤波后的估计 $[9.46, 1.32]^T$ ，而不是原始观测 9.7。若目标位置在 12 米附近，策略可能会选择轻微制动，而不是继续强烈加速，因为它已经判断机器人不仅接近目标，而且当前仍有正速度。

于是，滤波器塑造了策略输入；策略又决定了下一轮预测所依赖的控制动作。

8 它究竟带来了什么

卡尔曼滤波与强化学习的结合，至少有以下几个现实收益：

- 当原始观测含噪时，它往往提升样本效率；
- 它使控制信号更加平滑；
- 它以较有原则的方式处理部分可观测性；
- 它减轻了策略网络的负担，因为一部分状态推断工作已由估计器承担。

从工程视角看，这种方案把状态推断与决策优化分离开来，通常比让一个大模型从头同时学会二者更清晰。

9 它并不能神奇解决什么

这一方法也有明确边界。

9.1 线性与高斯假设

经典卡尔曼滤波在线性动力学和高斯噪声下才是精确的。许多强化学习环境并不满足这些条件。若系统包含接触、模式切换或强非线性传感器，经典卡尔曼滤波就可能过于乐观。此时通常需要转向扩展卡尔曼滤波、无迹卡尔曼滤波、粒子滤波，或学习型潜状态模型。

9.2 模型误差

若状态转移模型本身有偏差，滤波器就可能以很高置信度追踪错误的潜在状态。此时强化学习并不是在噪声上优化，而是在一个系统性扭曲的内部世界图景上优化。这种误差往往比单纯的随机噪声更危险。

9.3 回报设计并不会自动变简单

卡尔曼滤波帮助你估计状态，却不会替你定义目标。若回报函数设计不当，最终行为仍然会很差。估计质量与控制质量彼此相关，但它们从来不是同一个问题。

10 一个最小设计原则

对于初次实现而言，下面这条规则通常很难出错：

若观测含噪、状态并不完全可见、且短期动力学具有一定结构，那么应先构建状态估计器，再在其上训练强化学习策略。

这一路线并不追求新奇，却往往是现实系统中最正确的起点。

11 最后的观点

卡尔曼滤波与强化学习解决的是相邻但不同的问题。前者从不确定证据中估计隐藏状态，后者选择能够优化长期后果的动作。二者之所以能形成强有力的组合，是因为良好的决策依赖于良好的信念。

因此，不应把卡尔曼滤波仅仅看成一种轻量预处理。在部分可观测控制问题中，估计器本身就是系统智能的一部分。一个看错世界的策略，无论结构多复杂，都难以作出明智行为；一个建立在良好状态信念之上的策略，则更有希望学到稳定、节省数据且符合物理直觉的控制规律。