

粒子滤波基础笔记

从 Bayes 递推到重要性采样、重采样与数值算例

2026 年 3 月 30 日

目录

1	为什么需要粒子滤波	2
2	Bayes 滤波递推：粒子方法要近似的到底是什么	3
2.1	先看两个朴素例子	3
2.2	预测步	4
2.3	更新步	4
3	用粒子近似分布	5
4	从重要性采样推到权重递推	6
4.1	静态重要性采样	6
4.2	序贯重要性采样	6
4.3	Bootstrap 粒子滤波	6
5	重采样：为什么必须做，以及怎么判断何时做	7
5.1	权重退化	7
5.2	重采样的数学作用	7
5.3	常见选择	7
6	完整算法	8
7	算例一：双峰观测下的权重更新	8
7.1	模型设定	8
7.2	逐个计算似然	8
7.3	这组数字说明了什么	9
7.4	有效样本数	9

1	为什么需要粒子滤波	2
8	算例二：一维非线性运动的两步递推	9
8.1	模型	9
8.2	预测	9
8.3	更新	9
8.4	重采样	10
9	实现时真正要盯的量	10
9.1	粒子数 N	10
9.2	提议分布	10
9.3	重采样阈值	10
10	如果只记住几句话	10
A	术语与记号速查	11
A.1	这些东西通常在哪些课程里第一次见到	11
A.2	π_t 与 π_t^N 到底是什么	11
A.3	Dirac 质量是什么	11
A.4	经验测度是什么	12
A.5	先验、预测、后验分别是什么	12
A.6	为什么正文里要用这些写法	12
A.7	近似后验的两个朴素例子	12
A.8	二维数值例子：状态转移分布、提议分布与后验分布的区别	14
A.9	为什么粒子滤波能够跟踪时间演化的后验分布	17
A.10	后验期望为何写成积分，以及粒子估计量为何逼近真实后验期望	20
A.11	重采样为何保持条件期望不变	22
B	基础概率公式附录	25
B.1	全概率公式	25
B.2	Bayes 公式	25

1 为什么需要粒子滤波

Kalman filter 的核心优势，是把后验分布压缩成均值与协方差。只要系统近似线性、噪声近似高斯，这种压缩几乎不损失关键信息。

但如果后验分布本身不是单峰高斯，这种压缩就会失真。一个典型场景是：状态 x_t 是小车位置，观测却是

$$y_t = x_t^2 + v_t, \quad v_t \sim \mathcal{N}(0, \sigma_y^2).$$

当你测到 $y_t \approx 9$ 时， $x_t \approx 3$ 和 $x_t \approx -3$ 都有可能。后验天然呈现双峰结构，而不是单峰结构。此时若仍坚持用单个高斯去近似，就会把两个峰强行压缩为中间的一团分布。

粒子滤波的基本立场是：既然后验可能具有复杂结构，就不应强行将其压缩为单一的简单分布，而应直接用一批样本去近似整个后验。

2 Bayes 滤波递推：粒子方法要近似的到底是什么

考虑状态空间模型

$$x_t \sim p(x_t | x_{t-1}), \quad y_t \sim p(y_t | x_t),$$

其中状态空间记为 $\mathcal{X} \subseteq \mathbb{R}^d$, $x_t \in \mathcal{X}$ 是隐状态, y_t 是观测。我们的目标是递推计算后验密度

$$p(x_t | y_{1:t}), \quad y_{1:t} := (y_1, \dots, y_t).$$

2.1 先看两个朴素例子

如果一上来就看积分式，读者通常不知道自己到底在算什么。更好的方式，是先看一个离散例子，再看一个连续例子。

例 1：离散状态，其实就是“把所有旧状态的贡献加起来” 设小车此刻只可能在两个路口：左路口 L 或右路口 R 。上一时刻后验为

$$\mathbb{P}(x_{t-1} = L | y_{1:t-1}) = 0.7, \quad \mathbb{P}(x_{t-1} = R | y_{1:t-1}) = 0.3.$$

状态转移满足

$$\mathbb{P}(x_t = L | x_{t-1} = L) = 0.8, \quad \mathbb{P}(x_t = L | x_{t-1} = R) = 0.2.$$

那么由附录 [全概率公式](#) 的离散求和版，

$$\mathbb{P}(x_t = L | y_{1:t-1}) = \sum_{x_{t-1} \in \{L, R\}} \mathbb{P}(x_t = L | x_{t-1}) \mathbb{P}(x_{t-1} | y_{1:t-1}),$$

于是

$$\mathbb{P}(x_t = L | y_{1:t-1}) = 0.8 \times 0.7 + 0.2 \times 0.3 = 0.62.$$

这说明预测步并不神秘，本质上只是把“所有可能的旧状态”都过一遍，然后把它们对当前状态的贡献加起来。

现在假设传感器在时刻 t 给出观测 y_t ，且似然为

$$\mathbb{P}(y_t | x_t = L) = 0.9, \quad \mathbb{P}(y_t | x_t = R) = 0.2.$$

那么由附录 [Bayes 公式](#)，

$$\mathbb{P}(x_t = L | y_{1:t}) \propto \mathbb{P}(y_t | x_t = L) \mathbb{P}(x_t = L | y_{1:t-1}) = 0.9 \times 0.62 = 0.558,$$

$$\mathbb{P}(x_t = R | y_{1:t}) \propto 0.2 \times 0.38 = 0.076.$$

归一化后，

$$\mathbb{P}(x_t = L | y_{1:t}) = \frac{0.558}{0.558 + 0.076} \approx 0.88, \quad \mathbb{P}(x_t = R | y_{1:t}) \approx 0.12.$$

这就是更新步：先看预测分布，再用新观测重新分配可信度。

例 2：连续状态，其实就是“把所有旧位置的贡献累加起来” 现在把状态改成连续位置。设上一时刻我们认为小车位置 x_{t-1} 在区间 $[4, 6]$ 上均匀分布，即

$$p(x_{t-1} | y_{1:t-1}) = \begin{cases} \frac{1}{2}, & x_{t-1} \in [4, 6], \\ 0, & \text{其他}. \end{cases}$$

又设运动模型是

$$x_t = x_{t-1} + w_t, \quad w_t \sim \text{Unif}[0, 1],$$

于是转移密度为

$$p(x_t | x_{t-1}) = \begin{cases} 1, & x_t \in [x_{t-1}, x_{t-1} + 1], \\ 0, & \text{其他}. \end{cases}$$

这时若想算预测密度在 $x_t = 6$ 处的值，由附录 [全概率公式](#)，

$$p(x_t = 6 | y_{1:t-1}) = \int_{\mathcal{X}} p(6 | x_{t-1}) p(x_{t-1} | y_{1:t-1}) dx_{t-1}.$$

只有 $x_{t-1} \in [5, 6]$ 时，核 $p(6 | x_{t-1})$ 才不为零，因此

$$p(x_t = 6 | y_{1:t-1}) = \int_5^6 1 \cdot \frac{1}{2} dx_{t-1} = \frac{1}{2}.$$

同理，

$$p(x_t = 4.5 | y_{1:t-1}) = \int_4^{4.5} 1 \cdot \frac{1}{2} dx_{t-1} = \frac{1}{4}.$$

这说明连续情形下，积分并不是额外的神秘操作；它只是把“所有可能的旧位置”对当前点 x_t 的贡献连续地累加起来。收到观测后，再按

$$p(x_t | y_{1:t}) \propto p(y_t | x_t) p(x_t | y_{1:t-1})$$

把靠近观测的位置抬高、把远离观测的位置压低，这就是连续版的更新。

2.2 预测步

由附录 [全概率公式](#)，

$$p(x_t | y_{1:t-1}) = \int_{\mathcal{X}} p(x_t | x_{t-1}) p(x_{t-1} | y_{1:t-1}) dx_{t-1}.$$

这一步把上一时刻的后验经由状态转移核推到当前，称为预测分布。

2.3 更新步

由附录 [Bayes 公式](#)，

$$p(x_t | y_{1:t}) = \frac{p(y_t | x_t) p(x_t | y_{1:t-1})}{p(y_t | y_{1:t-1})}.$$

分母只是归一化常数，因此常写成

$$p(x_t | y_{1:t}) \propto p(y_t | x_t) p(x_t | y_{1:t-1}).$$

合起来，Bayes 滤波就是一条两步递推：

$$\begin{aligned} \text{预测: } p(x_t | y_{1:t-1}) &= \int_{\mathcal{X}} p(x_t | x_{t-1}) p(x_{t-1} | y_{1:t-1}) dx_{t-1}, \\ \text{更新: } p(x_t | y_{1:t}) &\propto p(y_t | x_t) p(x_t | y_{1:t-1}). \end{aligned}$$

难点不在公式，而在于这两个分布通常没有解析表达式。粒子滤波就是对这条递推的数值近似。若希望看“为什么这种数值近似会沿时间递推下去”的严格说明，可跳到附录 [为什么粒子滤波能够跟踪时间演化的后验分布](#)。

3 用粒子近似分布

如果你之前没系统学过 π_t^N 、Dirac 质量、经验测度、先验/预测/后验分布这些术语，可以先跳到附录 [术语与记号速查](#)；那一节专门解释这些词到底是什么意思，以及通常在哪些课程里第一次见到。

设一批粒子与权重为

$$\{x_t^{(i)}, w_t^{(i)}\}_{i=1}^N, \quad w_t^{(i)} \geq 0, \quad \sum_{i=1}^N w_t^{(i)} = 1.$$

粒子滤波用经验测度

$$\pi_t^N(dx) = \sum_{i=1}^N w_t^{(i)} \delta_{x_t^{(i)}}(dx)$$

近似目标后验 $\pi_t(dx) = p(x_t | y_{1:t}) dx$ 。这里 $\delta_{x_t^{(i)}}$ 是在粒子位置上的 Dirac 质量。若想先看两个直接可算的“近似后验”例子，可跳到附录 [近似后验的两个朴素例子](#)。

于是对任意测试函数 φ ，粒子系统自然诱导出一个后验期望的数值估计量：

$$\widehat{I}_t^N(\varphi) := \int_{\mathcal{X}} \varphi(x) \pi_t^N(dx) = \sum_{i=1}^N w_t^{(i)} \varphi(x_t^{(i)}).$$

这个定义之所以重要，是因为滤波并不只关心“分布存在”，还关心如何从分布里提取可计算的量。最常见的两个量，是后验均值与二阶矩；前者给出位置型估计，后者则进一步进入方差、协方差和不确定性分析。关于这里两个等号为何成立，以及它与真实后验期望之间究竟是什么关系，可跳到附录 [后验期望为何写成积分，以及粒子估计量为何逼近真实后验期望](#)。

因此，在 $\varphi(x) = x$ 和 $\varphi(x) = xx^\top$ 两个最常用的选择下，自然得到如下粒子估计量：

$$\widehat{m}_t^N := \sum_{i=1}^N w_t^{(i)} x_t^{(i)}, \quad \widehat{M}_t^N := \sum_{i=1}^N w_t^{(i)} x_t^{(i)} x_t^{(i)\top}.$$

它们分别用来估计

$$\mathbb{E}[x_t | y_{1:t}], \quad \mathbb{E}[x_t x_t^\top | y_{1:t}].$$

4 从重要性采样推到权重递推

4.1 静态重要性采样

设目标密度为 $\pi(x)$ ，难以直接采样；提议分布为 $q(x)$ ，容易采样，且 $q(x) > 0$ 在 $\pi(x)$ 的支撑上成立。则

$$\mathbb{E}_\pi[\varphi(x)] = \int_{\mathcal{X}} \varphi(x) \pi(x) dx = \int_{\mathcal{X}} \varphi(x) \frac{\pi(x)}{q(x)} q(x) dx = \mathbb{E}_q[\varphi(x) \omega(x)],$$

其中未归一化重要性权重定义为

$$\omega(x) := \frac{\pi(x)}{q(x)}.$$

若 $x^{(i)} \sim q$ ，则自归一化估计为

$$\mathbb{E}_\pi[\varphi(x)] \approx \sum_{i=1}^N \bar{w}^{(i)} \varphi(x^{(i)}), \quad \bar{w}^{(i)} = \frac{\omega(x^{(i)})}{\sum_{j=1}^N \omega(x^{(j)})}.$$

4.2 序贯重要性采样

在滤波问题中，目标分布随时间变化。设整条状态轨迹为 $x_{0:t}$ 。目标是后验

$$\pi_t(x_{0:t}) := p(x_{0:t} \mid y_{1:t}),$$

而提议分布取作

$$q_t(x_{0:t} \mid y_{1:t}) = q_{t-1}(x_{0:t-1} \mid y_{1:t-1}) q_t(x_t \mid x_{0:t-1}, y_{1:t}).$$

对应的未归一化权重为

$$\omega_t(x_{0:t}) = \frac{\pi_t(x_{0:t})}{q_t(x_{0:t} \mid y_{1:t})}.$$

利用

$$\pi_t(x_{0:t}) \propto p(y_t \mid x_t) p(x_t \mid x_{t-1}) \pi_{t-1}(x_{0:t-1}),$$

可得递推形式

$$\omega_t^{(i)} \propto \omega_{t-1}^{(i)} \frac{p(y_t \mid x_t^{(i)}) p(x_t^{(i)} \mid x_{t-1}^{(i)})}{q_t(x_t^{(i)} \mid x_{0:t-1}^{(i)}, y_{1:t})}.$$

这是序贯重要性采样的核心公式。如果此时还分不清“状态转移分布、提议分布、后验分布”三者各自扮演什么角色，可先跳到附录 [二维数值例子：状态转移分布、提议分布与后验分布的区别](#)；那一节专门用一个二维高斯例子把三者拆开比较。

4.3 Bootstrap 粒子滤波

若直接选提议分布

$$q_t(x_t \mid x_{0:t-1}, y_{1:t}) = p(x_t \mid x_{t-1}),$$

则上式中的状态转移项约掉，权重递推大幅简化为

$$\omega_t^{(i)} \propto \omega_{t-1}^{(i)} p(y_t | x_t^{(i)}).$$

这就是最经典的 Bootstrap particle filter。它的优点是实现简单；缺点是没有利用当前观测去设计更聪明的提议分布，故在观测很尖锐时容易权重退化。

5 重采样：为什么必须做，以及怎么判断何时做

5.1 权重退化

如果长时间只做重要性加权，不做重采样，通常会出现少数粒子拥有几乎全部权重，其余粒子权重接近零。此时虽名义上有 N 个粒子，实际有效样本远小于 N 。

常用诊断量是有效样本数

$$N_{\text{eff}} := \frac{1}{\sum_{i=1}^N (w_t^{(i)})^2}.$$

若所有权重都相等，则 $N_{\text{eff}} = N$ ；若一个粒子独占全部权重，则 $N_{\text{eff}} = 1$ 。

5.2 重采样的数学作用

重采样把带权粒子

$$\{x_t^{(i)}, w_t^{(i)}\}_{i=1}^N$$

转换为等权粒子

$$\{\tilde{x}_t^{(i)}, 1/N\}_{i=1}^N$$

并满足

$$\mathbb{E} \left[\frac{1}{N} \sum_{i=1}^N \varphi(\tilde{x}_t^{(i)}) \mid \{x_t^{(j)}, w_t^{(j)}\}_{j=1}^N \right] = \sum_{j=1}^N w_t^{(j)} \varphi(x_t^{(j)}).$$

这说明：在给定当前带权粒子的条件下，重采样后的等权经验平均至少在条件期望层面保持不变。之所以此处要强调这一点，是因为重采样虽然会复制和删除粒子，但我们仍希望它不要系统性地扭曲当前已经形成的后验统计量。关于这一条件期望公式为何成立，以及它为什么并不意味着“信息完全不损失”，可跳到附录 [重采样为何保持条件期望不变](#)。

5.3 常见选择

最简单的是 multinomial resampling。它直观，但方差偏大。实践中常用 systematic 或 stratified resampling，以降低采样方差。

6 完整算法

Bootstrap 粒子滤波可写成下述步骤：

1. 初始采样： $x_0^{(i)} \sim p(x_0)$ ，令 $w_0^{(i)} = 1/N$ 。

2. 预测：对每个粒子采样

$$x_t^{(i)} \sim p(x_t | x_{t-1}^{(i)}).$$

3. 加权：计算未归一化权重

$$\omega_t^{(i)} = w_{t-1}^{(i)} p(y_t | x_t^{(i)}),$$

再归一化成 $w_t^{(i)}$ 。

4. 若 $N_{\text{eff}} < N_{\text{thres}}$ ，则重采样并把权重重置为 $1/N$ 。

7 算例一：双峰观测下的权重更新

本节故意选一个一维、离散而短小的例子，用来手算权重。

7.1 模型设定

设当前时刻的预测粒子位置为

$$x_t^{(1)} = -3, \quad x_t^{(2)} = -1, \quad x_t^{(3)} = 1, \quad x_t^{(4)} = 3,$$

预测后它们等权，即 $w_{t|t-1}^{(i)} = 1/4$ 。

观测模型取为

$$y_t = x_t^2 + v_t, \quad v_t \sim \mathcal{N}(0, 1).$$

现在观测到 $y_t = 9$ 。

7.2 逐个计算似然

由高斯似然，

$$p(y_t = 9 | x_t^{(i)}) \propto \exp\left(-\frac{(9 - (x_t^{(i)})^2)^2}{2}\right).$$

四个粒子的平方分别为 9, 1, 1, 9，故未归一化权重与

$$\exp(0), \exp(-32), \exp(-32), \exp(0)$$

成正比。记 $a = \exp(-32) \approx 1.27 \times 10^{-14}$ ，则归一化后

$$w_t^{(1)} = \frac{1}{2 + 2a} \approx \frac{1}{2}, \quad w_t^{(4)} = \frac{1}{2 + 2a} \approx \frac{1}{2},$$

$$w_t^{(2)} = w_t^{(3)} = \frac{a}{2 + 2a} \approx 6.35 \times 10^{-15}.$$

7.3 这组数字说明了什么

更新后，后验几乎完全集中在 -3 与 3 两个粒子上。这个结果非常重要：粒子滤波没有把答案压成 0，而是保留了两个对称峰。若此时用单个高斯去拟合后验，均值会落在 0 附近，但 0 恰好是观测最不支持的位置之一。

7.4 有效样本数

此时

$$N_{\text{eff}} = \frac{1}{2(1/2)^2 + 2(6.35 \times 10^{-15})^2} \approx 2.$$

虽然共有 4 个粒子，但有效样本数约为 2。继续迭代后若退化加重，就应触发重采样。

8 算例二：一维非线性运动的两步递推

上一节只手算了一次更新；这一节写出一个完整的预测-更新-重采样回合。

8.1 模型

取状态模型

$$x_t = \frac{1}{2}x_{t-1} + w_t, \quad w_t \sim \mathcal{N}(0, 1),$$

观测模型

$$y_t = x_t^2 + v_t, \quad v_t \sim \mathcal{N}(0, 1).$$

假设上一时刻重采样后得到四个等权粒子

$$x_{t-1}^{(1)} = -4, \quad x_{t-1}^{(2)} = -2, \quad x_{t-1}^{(3)} = 2, \quad x_{t-1}^{(4)} = 4.$$

8.2 预测

为了算例简单，假设一次实际采样结果恰为

$$x_t^{(1)} = -3, \quad x_t^{(2)} = -1, \quad x_t^{(3)} = 1, \quad x_t^{(4)} = 3.$$

这组值与状态方程是相容的，因为对应噪声样本分别为 $-1, 0, 0, 1$ 。

8.3 更新

若观测仍是 $y_t = 9$ ，则权重就是上一节算出的结果，近似为

$$\left(\frac{1}{2}, 0, 0, \frac{1}{2}\right).$$

8.4 重采样

若做 multinomial resampling, 则新粒子会以概率 $1/2$ 从 -3 和 3 中抽取。一次可能的重采样结果为

$$\tilde{x}_t^{(1)} = -3, \quad \tilde{x}_t^{(2)} = -3, \quad \tilde{x}_t^{(3)} = 3, \quad \tilde{x}_t^{(4)} = 3.$$

这说明重采样虽把权重重新拉平, 但也明显减少了粒子多样性。这正是后续很多改进方法想要处理的问题。

9 实现时真正要盯的量

9.1 粒子数 N

N 太小时, 后验分布会被表示得过于粗糙; N 太大时, 计算开销上升。没有万能公式, 通常只能依据维度、观测尖锐程度和实时性要求去调。

9.2 提议分布

Bootstrap 方案最简单, 但不是最优。若观测很强, 应该尝试设计更靠近后验的提议分布, 否则权重容易一轮就塌。

9.3 重采样阈值

常见做法是在 $N_{\text{eff}} < N/2$ 或 $N_{\text{eff}} < 0.3N$ 时重采样。阈值过高会导致频繁重采样、样本贫化; 阈值过低则权重退化严重。

10 如果只记住几句话

1. 粒子滤波是在近似整条 Bayes 滤波递推, 而不是只在做“随机采样”。
2. 它用经验测度去逼近后验, 因此天然可以表示多峰和强非线性。
3. 重要性采样给出了权重公式, 重采样则是在控制权重退化。
4. 它的根本代价是: 表达能力来自大量样本, 算力与退化问题永远绕不开。

后续关系 在这份基础笔记之后, 粒子滤波还可以与最优输运或神经网络结合。但那是两条不同扩展线, 应分别讨论, 而不应混在一篇里。

A 术语与记号速查

A.1 这些东西通常在哪些课程里第一次见到

如果按课程来源粗分，大致是这样：

1. 概率论与数理统计：先验、后验、条件概率密度、Bayes 公式。
2. 随机过程或状态估计：状态空间模型、预测分布、滤波递推。
3. 测度论概率或更理论化的概率课：Dirac 质量、测度、经验测度这类写法。
4. Monte Carlo / 统计计算：重要性采样、粒子系统、经验分布近似。

所以如果你之前主要学的是“随机变量 + 密度函数 + 期望”那一套，而没正式学过测度论，那么 $\pi_t^N(dx)$ 这种写法看着陌生是完全正常的。

A.2 π_t 与 π_t^N 到底是什么

这里的 π_t 只是“时刻 t 的目标后验分布”的另一种写法。连续情形下，它对应

$$\pi_t(dx) = p(x_t \mid y_{1:t}) dx.$$

而 π_t^N 表示“用 N 个粒子构造出来的近似分布”：

$$\pi_t^N(dx) = \sum_{i=1}^N w_t^{(i)} \delta_{x_t^{(i)}}(dx).$$

这里上标 N 不是幂次，而是在提醒你：这个对象依赖于粒子数 N 。 N 变大时，通常希望 π_t^N 越来越接近真正的后验 π_t 。

A.3 Dirac 质量是什么

δ_a 表示“把全部质量都压在点 a 上”的分布，也叫 Dirac 质量或点质量。最核心的特征是：对任意测试函数 φ ，都有

$$\int_{\mathcal{X}} \varphi(x) \delta_a(dx) = \varphi(a).$$

如果你暂时不想碰测度论，可以把它粗略理解成：

δ_a 就是在说“这个随机量不散开，它只取点 a ”。

所以

$$\sum_{i=1}^N w_t^{(i)} \delta_{x_t^{(i)}}$$

的意思就是：把权重 $w_t^{(i)}$ 分配给点 $x_t^{(i)}$ ，从而得到一个“由很多带权点组成的分布”。

A.4 经验测度是什么

经验测度这个词听上去抽象，其实只是“把样本云写成分布对象”。

例如，若有三个等权样本

$$2, 5, 9,$$

那么对应的经验测度就是

$$\frac{1}{3}\delta_2 + \frac{1}{3}\delta_5 + \frac{1}{3}\delta_9.$$

它的意义是：以后你要算均值、方差或任意函数的期望时，不必每次都口头说“对三个样本取平均”，而可以统一写成“对经验测度积分”。比如

$$\int_{\mathcal{X}} x \left(\frac{1}{3}\delta_2 + \frac{1}{3}\delta_5 + \frac{1}{3}\delta_9 \right) (dx) = \frac{2+5+9}{3}.$$

因此，粒子滤波里的经验测度不是新物理对象，只是把“粒子 + 权重”这堆东西打包成一个分布。

A.5 先验、预测、后验分别是什么

这三个概念彼此接近，但含义并不相同。

1. 先验：在尚未利用当前观测之前，对状态所持有的分布性认识。
2. 预测分布：把上一时刻后验通过状态转移推到当前时刻后得到的分布，即 $p(x_t | y_{1:t-1})$ 。
3. 后验：融合了当前观测之后的分布，即 $p(x_t | y_{1:t})$ 。

在滤波语境里，可以将三者的关系概括为：

先由上一时刻信息形成预测分布，再结合当前观测完成后验更新。

A.6 为什么正文里要用这些写法

因为粒子滤波的本质不是只计算单个数值，而是在递推整条分布。只要关心的不仅是均值，而是完整的不确定性结构，那么 π_t 、 π_t^N 、 δ_a 这一套写法会比单独书写密度函数更紧凑，也更适合同时处理离散与连续情形。

A.7 近似后验的两个朴素例子

例 1：离散状态时，近似后验就是带权计数 设状态空间只有三个位置

$$\mathcal{X} = \{A, B, C\}.$$

假设真实后验为

$$\pi_t(\{A\}) = 0.1, \quad \pi_t(\{B\}) = 0.3, \quad \pi_t(\{C\}) = 0.6.$$

现在若粒子滤波给出 $N = 5$ 个等权粒子

$$C, C, B, C, A,$$

则经验测度就是

$$\pi_t^5 = \frac{1}{5}\delta_A + \frac{1}{5}\delta_B + \frac{3}{5}\delta_C.$$

这时它对三个状态给出的近似概率分别是

$$\pi_t^5(\{A\}) = \frac{1}{5}, \quad \pi_t^5(\{B\}) = \frac{1}{5}, \quad \pi_t^5(\{C\}) = \frac{3}{5}.$$

它与真实后验

$$(0.1, 0.3, 0.6)$$

并不完全相同，但已经抓住了最主要的结构：状态 C 概率最大，状态 A 最小。这里“近似后验”没有任何神秘之处，本质上就是“看有多少粒子落在各个状态上”。

例 2：连续状态时，近似后验就是带权点去逼近平滑分布 现在设状态是连续位置，真实后验是一条平滑密度曲线，例如大致集中在 $x = 2$ 附近。粒子滤波给出三个带权粒子

$$\begin{aligned} x_t^{(1)} &= 0, & x_t^{(2)} &= 2, & x_t^{(3)} &= 3, \\ w_t^{(1)} &= 0.2, & w_t^{(2)} &= 0.5, & w_t^{(3)} &= 0.3. \end{aligned}$$

那么近似后验写成

$$\pi_t^3(dx) = 0.2\delta_0(dx) + 0.5\delta_2(dx) + 0.3\delta_3(dx).$$

这不表示真实后验真的只在 $0, 2, 3$ 三个点取值，而是表示：

我们暂时只用这三个带权点来代表整条连续后验曲线。

例如，它给出的后验均值近似为

$$\int_{\mathcal{X}} x \pi_t^3(dx) = 0.2 \times 0 + 0.5 \times 2 + 0.3 \times 3 = 1.9.$$

若要近似区间 $[1.5, 3.5]$ 上的后验概率，则只需把落在区间内的粒子权重相加：

$$\pi_t^3([1.5, 3.5]) \approx 0.5 + 0.3 = 0.8.$$

因此，连续情形下所谓“近似后验”，本质上就是：真实对象是一条连续密度曲线，而计算机里我们改用有限个带权点来替代它，并用这些权重去近似均值、区间概率和其他期望量。

对应的最小 Python 脚本 如果不想手算，这两个量也可以直接用一个最小脚本算出来。仓库里附了 [examples/simple_particle_demo.py](#)，运行方式是：

```
pythonnotes/ _ /examples/simple_particle_demo.py
```

这个脚本会直接输出：

1. 带权粒子的后验均值估计；
2. 二阶矩估计；
3. 区间 $[1.5, 3.5]$ 的后验概率估计；
4. 一次 multinomial resampling 的具体结果。

因此读者既可以跟着附录手算，也可以立即用代码核对。

A.8 二维数值例子：状态转移分布、提议分布与后验分布的区别

这三个对象最容易混淆，因此单独给一个二维例子。

模型设定 为了只研究这三个分布的角色区别，我们先把上一时刻状态固定为

$$x_{t-1} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

设系统动力学给出的状态转移分布为

$$p(x_t | x_{t-1}) = \mathcal{N}\left(\begin{bmatrix} 1 \\ 1 \end{bmatrix}, I_2\right).$$

这表示：如果只看系统运动规律，不看当前观测，那么下一时刻状态大致在 $(1, 1)$ 附近，且不确定性较大。

当前观测模型取为

$$y_t | x_t \sim \mathcal{N}(x_t, 0.04 I_2), \quad y_t = \begin{bmatrix} 2.8 \\ 2.6 \end{bmatrix}.$$

这表示观测非常集中，强烈支持 x_t 靠近 $(2.8, 2.6)$ 。

第一步：状态转移分布在说什么 状态转移分布

$$p(x_t | x_{t-1})$$

只回答一个问题：

如果暂时不看当前观测，系统本身倾向于怎样运动？

在这个例子里，它把大量质量放在 $(1, 1)$ 附近，因此这是系统先验上的“自然推进方向”。

第二步：后验分布在说什么 真正想逼近的对象是后验分布

$$p(x_t | y_t, x_{t-1}) \propto p(y_t | x_t) p(x_t | x_{t-1}).$$

由于这里转移与观测都是高斯，后验仍然是高斯，而且可以直接算出

$$p(x_t | y_t, x_{t-1}) = \mathcal{N}\left(\begin{bmatrix} 2.7308 \\ 2.5385 \end{bmatrix}, \frac{1}{26} I_2\right).$$

所以后验的中心已经明显从 (1, 1) 被拉向了观测附近。这说明：后验不是单纯的“系统如何运动”，而是“系统运动规律与当前观测共同作用后的结果”。

第三步：提议分布在说什么 提议分布

$$q_t(x_t | x_{t-1}, y_t)$$

回答的不是“世界如何运动”，也不是“真实后验是什么”，而是：

算法实际准备从哪里抽样来生成候选粒子？

因此它是算法设计对象，而不是物理真相本身。

第四步：Bootstrap 提议为何容易退化 若直接取 Bootstrap 提议

$$q_{\text{boot}}(x_t | x_{t-1}, y_t) = p(x_t | x_{t-1}),$$

也就是直接拿状态转移分布来采样。那么一组可能的二维粒子为

$$(0.2, 1.4), \quad (1.1, 0.3), \quad (2.0, 1.8), \quad (-0.1, 0.7).$$

由于此时 $q_{\text{boot}} = p(x_t | x_{t-1})$ ，归一化前权重只与似然

$$p(y_t | x_t^{(i)})$$

成正比。数值上，归一化权重几乎变成

$$(0, 0, 1, 0).$$

对应的有效样本数约为

$$N_{\text{eff}} \approx 1.$$

这说明：虽然系统转移允许算法在 (1, 1) 附近广泛采样，但当前观测非常尖锐，导致大部分粒子与观测不相容，于是权重几乎全部塌缩到一个粒子上。

第五步：一个更靠近后验的提议分布 现在改用一個观测引导的提议分布：

$$q_{\text{guide}}(x_t \mid x_{t-1}, y_t) = \mathcal{N}\left(\begin{bmatrix} 2.7 \\ 2.5 \end{bmatrix}, 0.09 I_2\right).$$

这不是后验本身，但它刻意把采样中心放到了后验高概率区域附近。此时一组可能采样为

$$(2.5, 2.3), \quad (2.8, 2.6), \quad (2.6, 2.7), \quad (3.0, 2.4).$$

对应的重要性权重不再只由似然决定，而是

$$\omega_t^{(i)} \propto \frac{p(y_t \mid x_t^{(i)}) p(x_t^{(i)} \mid x_{t-1})}{q_{\text{guide}}(x_t^{(i)} \mid x_{t-1}, y_t)}.$$

数值上，归一化权重大致为

$$(0.140, 0.377, 0.284, 0.199),$$

对应有效样本数约为

$$N_{\text{eff}} \approx 3.55.$$

与前面的 $N_{\text{eff}} \approx 1$ 相比，这说明更合适的提议分布会让粒子更早落在后验高概率区域，从而显著减轻退化。

第六步：三者到底怎么区分 这个二维例子里，三者的角色已经完全不同：

1. 状态转移分布：系统本身怎么运动。在本例中，它把质量放在 (1,1) 附近。
2. 提议分布：算法实际从哪里抽粒子。它可以等于状态转移分布，也可以更靠近观测。
3. 后验分布：结合观测后真正想逼近的目标。在本例中，它集中在 (2.7308, 2.5385) 附近。

对应的 Python 脚本 仓库里附了 [examples/proposal_2d_demo.py](#)，运行方式是：

```
python3 notes/ _ /examples/proposal_2d_demo.py
```

该脚本会直接输出：

1. 解析后验的均值与协方差；
2. Bootstrap 提议下的归一化权重与有效样本数；
3. 观测引导提议下的归一化权重与有效样本数。

这样就可以直观看到：提议分布不是后验本身，但它的选择会极大影响粒子滤波的数值效率。

A.9 为什么粒子滤波能够跟踪时间演化的后验分布

正文里说过一句话：粒子滤波之所以能够跟踪“分布随时间的演化”，不是因为粒子本身神奇，而是因为它在数值上逼近了 Bayes 滤波递推。下面把这句话写成一个严格的命题。

第一步：把滤波递推写成两个算子 设状态空间为 $\mathcal{X}$ ，状态转移核为

$$K_t(\xi, A) := \mathbb{P}(x_t \in A \mid x_{t-1} = \xi),$$

观测似然记为

$$g_t(x) := p(y_t \mid x).$$

给定任意概率测度 μ ，定义预测算子

$$\Phi_t(\mu)(A) := \int_{\mathcal{X}} K_t(\xi, A) \mu(d\xi),$$

以及更新算子

$$\Psi_t(\mu)(dx) := \frac{g_t(x) \mu(dx)}{\int_{\mathcal{X}} g_t(z) \mu(dz)}.$$

于是 Bayes 滤波递推可以压缩写成

$$\bar{\pi}_t = \Phi_t(\pi_{t-1}), \quad \pi_t = \Psi_t(\bar{\pi}_t),$$

其中 $\bar{\pi}_t$ 是预测分布， π_t 是后验分布。

第二步：先说明要证明什么 粒子滤波在时刻 $t-1$ 给出一个近似测度 π_{t-1}^N 。我们真正想证明的是：

如果 π_{t-1}^N 已经逼近 π_{t-1} ，那么经过预测算子和更新算子之后，新的近似 π_t^N 仍然逼近 π_t 。

这正是“它能够跟踪时间演化分布”的数学内容。

第三步：一般情形下的命题 设 φ 是任意有界连续测试函数，并假设：

1. $\pi_{t-1}^N \Rightarrow \pi_{t-1}$ 弱收敛；
2. 转移核 K_t 具有 Feller 性质，即对任意有界连续 φ ，函数

$$(K_t \varphi)(\xi) := \int_{\mathcal{X}} \varphi(x) K_t(\xi, dx)$$

仍是有界连续函数；

3. 似然 g_t 有界、连续，且

$$\int_{\mathcal{X}} g_t(x) \Phi_t(\pi_{t-1})(dx) > 0.$$

定义

$$\bar{\pi}_t^N := \Phi_t(\pi_{t-1}^N), \quad \pi_t^N := \Psi_t(\bar{\pi}_t^N).$$

则有

$$\bar{\pi}_t^N \Rightarrow \bar{\pi}_t, \quad \pi_t^N \Rightarrow \pi_t.$$

第四步：预测步的严格证明 对任意有界连续 φ ，有

$$\int_{\mathcal{X}} \varphi(x) \bar{\pi}_t^N(dx) = \int_{\mathcal{X}} \varphi(x) \Phi_t(\pi_{t-1}^N)(dx).$$

按 Φ_t 的定义改写：

$$\int_{\mathcal{X}} \varphi(x) \bar{\pi}_t^N(dx) = \int_{\mathcal{X}} \left(\int_{\mathcal{X}} \varphi(x) K_t(\xi, dx) \right) \pi_{t-1}^N(d\xi).$$

记

$$(K_t\varphi)(\xi) := \int_{\mathcal{X}} \varphi(x) K_t(\xi, dx),$$

则上式化为

$$\int_{\mathcal{X}} \varphi(x) \bar{\pi}_t^N(dx) = \int_{\mathcal{X}} (K_t\varphi)(\xi) \pi_{t-1}^N(d\xi).$$

由于 K_t 具有 Feller 性质， $K_t\varphi$ 仍是有界连续函数；再由 $\pi_{t-1}^N \Rightarrow \pi_{t-1}$ ，得到

$$\int_{\mathcal{X}} (K_t\varphi)(\xi) \pi_{t-1}^N(d\xi) \rightarrow \int_{\mathcal{X}} (K_t\varphi)(\xi) \pi_{t-1}(d\xi).$$

把定义代回，即

$$\int_{\mathcal{X}} \varphi(x) \bar{\pi}_t^N(dx) \rightarrow \int_{\mathcal{X}} \varphi(x) \bar{\pi}_t(dx).$$

因此

$$\bar{\pi}_t^N \Rightarrow \bar{\pi}_t.$$

第五步：更新步的严格证明 更新后，对任意有界连续 φ ，有

$$\int_{\mathcal{X}} \varphi(x) \pi_t^N(dx) = \frac{\int_{\mathcal{X}} \varphi(x) g_t(x) \bar{\pi}_t^N(dx)}{\int_{\mathcal{X}} g_t(x) \bar{\pi}_t^N(dx)}.$$

因为 φ 与 g_t 都有界连续，所以 φg_t 与 g_t 仍是有界连续函数。由刚证明的 $\bar{\pi}_t^N \Rightarrow \bar{\pi}_t$ ，便有

$$\int_{\mathcal{X}} \varphi(x) g_t(x) \bar{\pi}_t^N(dx) \rightarrow \int_{\mathcal{X}} \varphi(x) g_t(x) \bar{\pi}_t(dx),$$

$$\int_{\mathcal{X}} g_t(x) \bar{\pi}_t^N(dx) \rightarrow \int_{\mathcal{X}} g_t(x) \bar{\pi}_t(dx).$$

又由于极限分母严格为正，因此商收敛，于是

$$\int_{\mathcal{X}} \varphi(x) \pi_t^N(dx) \rightarrow \int_{\mathcal{X}} \varphi(x) \pi_t(dx).$$

这就证明了

$$\pi_t^N \Rightarrow \pi_t.$$

第六步：这一定理真正说明了什么 它说明：粒子滤波之所以能跟踪时间演化的后验分布，并不是因为“粒子会自动长成正确形状”，而是因为 Bayes 递推本身可分解为预测算子与更新算子，而这两个算子在适当条件下都会保留近似的一致性。

换句话说：

上一时刻若近似正确，下一时刻经过 Bayes 预测与更新后，近似仍然可以继续传递下去。

第七步：这和实际粒子滤波之间还差哪一步 上面的命题把重点放在“Bayes 算子如何传递近似”上。真正的粒子滤波还包含采样和重采样的随机机制，因此完整证明通常还要再加上：

1. 采样经验测度对目标测度的一致性；
2. 重采样步骤的条件无偏性与方差控制；
3. 逐时刻归纳，得到整个粒子系统的一致性。

但从结构上讲，决定它为何能跟踪时间演化分布的核心，正是上面这条“Bayes 算子保一致性”的命题。

第八步：一维状态的简化证明 现在把状态空间专门取成 $\mathcal{X} = \mathbb{R}$ ，并设上一时刻的粒子近似为

$$\pi_{t-1}^N(d\xi) = \sum_{i=1}^N w_{t-1}^{(i)} \delta_{x_{t-1}^{(i)}}(d\xi).$$

设转移密度写成

$$k_t(x | \xi),$$

于是预测近似测度为

$$\bar{\pi}_t^N(dx) = \sum_{i=1}^N w_{t-1}^{(i)} k_t(x | x_{t-1}^{(i)}) dx.$$

取任意有界连续测试函数 $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ 。则

$$\int_{\mathbb{R}} \varphi(x) \bar{\pi}_t^N(dx) = \sum_{i=1}^N w_{t-1}^{(i)} \int_{\mathbb{R}} \varphi(x) k_t(x | x_{t-1}^{(i)}) dx.$$

定义

$$T_t \varphi(\xi) := \int_{\mathbb{R}} \varphi(x) k_t(x | \xi) dx,$$

则上式可写成

$$\int_{\mathbb{R}} \varphi(x) \bar{\pi}_t^N(dx) = \sum_{i=1}^N w_{t-1}^{(i)} T_t \varphi(x_{t-1}^{(i)}) = \int_{\mathbb{R}} T_t \varphi(\xi) \pi_{t-1}^N(d\xi).$$

若 $\pi_{t-1}^N \Rightarrow \pi_{t-1}$ ，且 $T_t \varphi$ 有界连续，则

$$\int_{\mathbb{R}} T_t \varphi(\xi) \pi_{t-1}^N(d\xi) \rightarrow \int_{\mathbb{R}} T_t \varphi(\xi) \pi_{t-1}(d\xi) = \int_{\mathbb{R}} \varphi(x) \bar{\pi}_t(dx).$$

因此预测步保持一致性。

再设似然函数为

$$g_t(x) = p(y_t | x).$$

更新后的粒子测度定义为

$$\pi_t^N(dx) = \frac{g_t(x) \bar{\pi}_t^N(dx)}{\int_{\mathbb{R}} g_t(z) \bar{\pi}_t^N(dz)}.$$

于是

$$\int_{\mathbb{R}} \varphi(x) \pi_t^N(dx) = \frac{\int_{\mathbb{R}} \varphi(x) g_t(x) \bar{\pi}_t^N(dx)}{\int_{\mathbb{R}} g_t(x) \bar{\pi}_t^N(dx)}.$$

若 $\bar{\pi}_t^N \Rightarrow \bar{\pi}_t$ ，且 φg_t 、 g_t 都有界连续，分母极限严格正，则分子分母分别收敛，从而

$$\int_{\mathbb{R}} \varphi(x) \pi_t^N(dx) \rightarrow \int_{\mathbb{R}} \varphi(x) \pi_t(dx).$$

因此一维情形下，粒子近似之所以能够随时间跟踪后验分布，本质上仍然是：预测算子与更新算子把上一时刻的近似继续传到了下一时刻。

A.10 后验期望为何写成积分，以及粒子估计量为何逼近真实后验期望

正文里出现过下面这一步：

$$\hat{I}_t^N(\varphi) := \int_{\mathcal{X}} \varphi(x) \pi_t^N(dx) = \sum_{i=1}^N w_t^{(i)} \varphi(x_t^{(i)}).$$

而它所对应的真实目标量是

$$I_t(\varphi) := \mathbb{E}[\varphi(x_t) \mid y_{1:t}] = \int_{\mathcal{X}} \varphi(x) \pi_t(dx).$$

对初学者而言，最容易困惑的是：这些等号各自依据什么，以及为什么 $\hat{I}_t^N(\varphi)$ 可以拿来估计 $I_t(\varphi)$ 。下面分开说明。

第一步：为什么 $\mathbb{E}[\varphi(x_t) \mid y_{1:t}] = \int_{\mathcal{X}} \varphi(x) \pi_t(dx)$ 是等号 这一步没有做任何近似，它只是把“条件期望”换写成“对后验分布积分”。

因为我们已经把时刻 t 的后验分布记成

$$\pi_t(dx) = p(x_t \mid y_{1:t}) dx.$$

所以按照期望对分布积分的定义，

$$\mathbb{E}[\varphi(x_t) \mid y_{1:t}] = \int_{\mathcal{X}} \varphi(x) p(x_t \mid y_{1:t}) dx = \int_{\mathcal{X}} \varphi(x) \pi_t(dx).$$

因此这里的等号只是记号改写：左边是“条件期望”的写法，右边是“相对于后验分布积分”的写法，二者表示的是同一个量。

第二步：粒子滤波并不直接得到 π_t ，而是先构造经验测度 粒子滤波输出的是粒子与权重，因此首先得到的是经验测度

$$\pi_t^N(dx) = \sum_{i=1}^N w_t^{(i)} \delta_{x_t^{(i)}}(dx).$$

于是把 φ 对 π_t^N 积分，就定义出粒子估计量

$$\hat{I}_t^N(\varphi) := \int_{\mathcal{X}} \varphi(x) \pi_t^N(dx) = \int_{\mathcal{X}} \varphi(x) \left(\sum_{i=1}^N w_t^{(i)} \delta_{x_t^{(i)}}(dx) \right).$$

第三步：为什么 $\hat{I}_t^N(\varphi) = \sum_{i=1}^N w_t^{(i)} \varphi(x_t^{(i)})$ 仍然是等号 这一步同样不是近似，而是 Dirac 质量的定义性性质。

先把常数权重提出，再逐项积分：

$$\hat{I}_t^N(\varphi) = \sum_{i=1}^N w_t^{(i)} \int_{\mathcal{X}} \varphi(x) \delta_{x_t^{(i)}}(dx).$$

而 Dirac 质量满足

$$\int_{\mathcal{X}} \varphi(x) \delta_{x_t^{(i)}}(dx) = \varphi(x_t^{(i)}).$$

代回即得

$$\hat{I}_t^N(\varphi) = \sum_{i=1}^N w_t^{(i)} \varphi(x_t^{(i)}).$$

所以这一小步仍然是严格等式。

第四步：逼近关系究竟发生在哪里 真正需要说明的，不是“积分如何变成求和”，而是经验测度为何可以逼近真实后验。更准确地说，我们需要的是

$$\hat{I}_t^N(\varphi) - I_t(\varphi) \rightarrow 0 \quad (N \rightarrow \infty)$$

这样的收敛结论。若用概率收敛来表述，可以写成

$$\hat{I}_t^N(\varphi) - I_t(\varphi) \xrightarrow{\mathbb{P}} 0, \quad N \rightarrow \infty,$$

其中需要对模型、权重和测试函数 φ 施加适当假设。这才是严格的数学表述。

如果进一步研究中心极限定理，常可得到更细的误差尺度，例如

$$\hat{I}_t^N(\varphi) - I_t(\varphi) = O_{\mathbb{P}}(N^{-1/2}),$$

但这已经依赖更强的技术条件，不能在正文里不加说明地直接写成一个普通的“约等于”。

第五步：把逻辑压缩成一句话 因此，正确的理解顺序不是

积分大概等于求和，

而是

先定义真实目标量 $I_t(\varphi)$ ，再定义粒子估计量 $\hat{I}_t^N(\varphi)$ ；随后在一致性或渐近理论下证明 $\hat{I}_t^N(\varphi)$ 逼近 $I_t(\varphi)$ 。

一个最小数值例子 设

$$\pi_t^3(dx) = 0.2 \delta_0(dx) + 0.5 \delta_2(dx) + 0.3 \delta_3(dx), \quad \varphi(x) = x^2.$$

那么

$$= \hat{I}_t^3(\varphi) = \int_{\mathcal{X}} x^2 \pi_t^3(dx) = 0.2 \cdot 0^2 + 0.5 \cdot 2^2 + 0.3 \cdot 3^2 = 4.7.$$

这里最后一步不是近似，而是严格计算。若进一步用它估计

$$I_t(x^2) = \mathbb{E}[x_t^2 \mid y_{1:t}] = \int_{\mathcal{X}} x^2 \pi_t(dx),$$

则严格写法应是考察误差

$$\hat{I}_t^3(x^2) - I_t(x^2),$$

并在 N 增大时讨论它是否趋于 0，而不是直接写一个没有说明误差含义的近似号。

A.11 重采样为何保持条件期望不变

正文里写过下面这条公式：

$$\mathbb{E} \left[\frac{1}{N} \sum_{i=1}^N \varphi(\tilde{x}_t^{(i)}) \mid \{x_t^{(j)}, w_t^{(j)}\}_{j=1}^N \right] = \sum_{j=1}^N w_t^{(j)} \varphi(x_t^{(j)}).$$

这句话看起来很强，因此必须先问：为什么这里要研究它？

第一步：为什么要引入这条公式 因为重采样会把带权粒子

$$\{x_t^{(j)}, w_t^{(j)}\}_{j=1}^N$$

改成等权粒子

$$\{\tilde{x}_t^{(i)}, 1/N\}_{i=1}^N.$$

这一过程显然会改变样本的具体排列，甚至会删除一些粒子、复制另一些粒子。因此自然要追问：

重采样之后，我们用等权粒子算出来的平均量，会不会系统性偏离重采样之前的带权平均？

上面的条件期望公式正是在回答这个问题。它说明：至少对经验平均而言，multinomial resampling 在条件期望意义下是无偏的。

第二步：先把重采样写成随机索引 以 multinomial resampling 为例。给定当前粒子与权重后，重采样等价于独立抽取索引

$$A_1, \dots, A_N \in \{1, \dots, N\},$$

并满足

$$\mathbb{P}(A_i = j \mid \{x_t^{(k)}, w_t^{(k)}\}_{k=1}^N) = w_t^{(j)}.$$

然后定义

$$\tilde{x}_t^{(i)} := x_t^{(A_i)}.$$

也就是说，每个新粒子都是“按权重随机选一个旧粒子作为祖先”得到的。

第三步：先求单个重采样粒子的条件期望 固定某个 i 。在给定当前粒子与权重的条件下，

$$\mathbb{E}[\varphi(\tilde{x}_t^{(i)}) \mid \{x_t^{(k)}, w_t^{(k)}\}_{k=1}^N] = \sum_{j=1}^N \mathbb{P}(A_i = j \mid \{x_t^{(k)}, w_t^{(k)}\}_{k=1}^N) \varphi(x_t^{(j)}).$$

把条件概率替换成权重，即得

$$\mathbb{E}[\varphi(\tilde{x}_t^{(i)}) \mid \{x_t^{(k)}, w_t^{(k)}\}_{k=1}^N] = \sum_{j=1}^N w_t^{(j)} \varphi(x_t^{(j)}).$$

这说明：单个重采样粒子的函数值，其条件期望就已经等于原先的带权平均。

第四步：再推广到 N 个等权粒子的平均 现在看重采样后的等权经验平均：

$$\frac{1}{N} \sum_{i=1}^N \varphi(\tilde{x}_t^{(i)}).$$

对它取条件期望，并利用期望的线性性，有

$$\mathbb{E}\left[\frac{1}{N} \sum_{i=1}^N \varphi(\tilde{x}_t^{(i)}) \mid \{x_t^{(k)}, w_t^{(k)}\}_{k=1}^N\right] = \frac{1}{N} \sum_{i=1}^N \mathbb{E}[\varphi(\tilde{x}_t^{(i)}) \mid \{x_t^{(k)}, w_t^{(k)}\}_{k=1}^N].$$

代入上一步结果：

$$\mathbb{E}\left[\frac{1}{N} \sum_{i=1}^N \varphi(\tilde{x}_t^{(i)}) \mid \{x_t^{(k)}, w_t^{(k)}\}_{k=1}^N\right] = \frac{1}{N} \sum_{i=1}^N \sum_{j=1}^N w_t^{(j)} \varphi(x_t^{(j)}).$$

由于右边与 i 无关，故

$$\mathbb{E}\left[\frac{1}{N} \sum_{i=1}^N \varphi(\tilde{x}_t^{(i)}) \mid \{x_t^{(k)}, w_t^{(k)}\}_{k=1}^N\right] = \sum_{j=1}^N w_t^{(j)} \varphi(x_t^{(j)}).$$

这就得到正文中的条件期望公式。

第五步：这条公式到底说明了什么，又没有说明什么 它说明的是：

重采样后的等权经验平均，在条件期望意义下，与重采样前的带权经验平均一致。

但它没有说明：

1. 单次重采样的结果一定等于原带权平均；
2. 重采样不会增加方差；
3. 重采样不会降低样本多样性。

恰恰相反，重采样通常会引入额外随机性，并可能导致粒子复制，从而降低多样性。它保住的是“条件期望无偏”，而不是“每次实现都无损”。

一个最小离散例子 设当前只有两个粒子

$$x_t^{(1)} = 0, \quad x_t^{(2)} = 10,$$

权重为

$$w_t^{(1)} = 0.8, \quad w_t^{(2)} = 0.2.$$

取测试函数 $\varphi(x) = x$ 。则重采样前的带权平均为

$$0.8 \cdot 0 + 0.2 \cdot 10 = 2.$$

若 $N = 2$ 并做 multinomial resampling，则每个新粒子都以概率 0.8 取 0，以概率 0.2 取 10。于是单个新粒子的条件期望为

$$\mathbb{E}[\tilde{x}_t^{(i)} \mid \{x_t^{(j)}, w_t^{(j)}\}_{j=1}^2] = 0.8 \cdot 0 + 0.2 \cdot 10 = 2.$$

因此

$$\mathbb{E}\left[\frac{\tilde{x}_t^{(1)} + \tilde{x}_t^{(2)}}{2} \mid \{x_t^{(j)}, w_t^{(j)}\}_{j=1}^2\right] = 2.$$

但一次具体实现可能是

$$(0, 0), \quad (0, 10), \quad (10, 0), \quad (10, 10),$$

它们对应的等权平均分别是

$$0, \quad 5, \quad 5, \quad 10.$$

可见单次结果波动很大；真正保持不变的是条件期望，而不是每次实现本身。

B 基础概率公式附录

B.1 全概率公式

设 X 与 Y 具有联合密度 $p(x, y)$, 其中 $x \in \mathcal{X}$ 。则边缘密度可由条件密度积分得到:

$$p(y) = \int_{\mathcal{X}} p(y | x) p(x) dx.$$

在条件化情形下, 如果再给定一个额外信息集 $\mathcal{G}$, 同样有

$$p(y | \mathcal{G}) = \int_{\mathcal{X}} p(y | x, \mathcal{G}) p(x | \mathcal{G}) dx.$$

粒子滤波预测步正是在 $\mathcal{G} = y_{1:t-1}$ 的条件下, 对上式的直接应用。

B.2 Bayes 公式

在同样设定下, 若 $p(y) > 0$, 则后验密度满足

$$p(x | y) = \frac{p(y | x) p(x)}{p(y)}.$$

其中分母也可以借助全概率公式写成

$$p(y) = \int_{\mathcal{X}} p(y | x) p(x) dx.$$

若给定额外信息集 $\mathcal{G}$, 则条件版 Bayes 公式为

$$p(x | y, \mathcal{G}) = \frac{p(y | x, \mathcal{G}) p(x | \mathcal{G})}{p(y | \mathcal{G})}.$$

粒子滤波更新步对应的是 $\mathcal{G} = y_{1:t-1}$ 的特殊情形。