

粒子滤波基础笔记

从 Bayes 递推到重要性采样、重采样与数值算例

2026 年 3 月 30 日

目录

1	为什么需要粒子滤波	2
2	Bayes 滤波递推：粒子方法要近似的到底是什么	3
2.1	先看两个朴素例子	3
2.2	预测步	4
2.3	更新步	4
3	用粒子近似分布	5
4	从重要性采样推到权重递推	5
4.1	静态重要性采样	5
4.2	序贯重要性采样	6
4.3	Bootstrap 粒子滤波	6
5	重采样：为什么必须做，以及怎么判断何时做	7
5.1	权重退化	7
5.2	重采样的数学作用	7
5.3	常见选择	7
6	完整算法	7
7	算例一：双峰观测下的权重更新	8
7.1	模型设定	8
7.2	逐个计算似然	8
7.3	这组数字说明了什么	8
7.4	有效样本数	8

1 为什么需要粒子滤波	2
8 算例二：一维非线性运动的两步递推	9
8.1 模型	9
8.2 预测	9
8.3 更新	9
8.4 重采样	9
9 实现时真正要盯的量	9
9.1 粒子数 N	9
9.2 提议分布	10
9.3 重采样阈值	10
10 如果只记住几句话	10
A 术语与记号速查	10
A.1 这些东西通常在哪些课程里第一次见到	10
A.2 π_t 与 π_t^N 到底是什么	11
A.3 Dirac 质量是什么	11
A.4 经验测度是什么	11
A.5 先验、预测、后验分别是什么	12
A.6 为什么正文里要用这些写法	12
A.7 近似后验的两个朴素例子	12
B 基础概率公式附录	13
B.1 全概率公式	13
B.2 Bayes 公式	14

1 为什么需要粒子滤波

Kalman filter 的核心优势，是把后验分布压缩成均值与协方差。只要系统近似线性、噪声近似高斯，这种压缩几乎不损失关键信息。

但如果后验分布本身不是单峰高斯，这种压缩就会失真。一个典型场景是：状态 x_t 是小车位置，观测却是

$$y_t = x_t^2 + v_t, \quad v_t \sim \mathcal{N}(0, \sigma_y^2).$$

当你测到 $y_t \approx 9$ 时， $x_t \approx 3$ 和 $x_t \approx -3$ 都有可能。后验天然呈现双峰结构，而不是单峰结构。此时若仍坚持用单个高斯去近似，就会把两个峰强行压缩为中间的一团分布。

粒子滤波的基本立场是：既然后验可能具有复杂结构，就不应强行将其压缩为单一的简单分布，而应直接用一批样本去近似整个后验。

2 Bayes 滤波递推：粒子方法要近似的到底是什么

考虑状态空间模型

$$x_t \sim p(x_t | x_{t-1}), \quad y_t \sim p(y_t | x_t),$$

其中状态空间记为 $\mathcal{X} \subseteq \mathbb{R}^d$, $x_t \in \mathcal{X}$ 是隐状态, y_t 是观测。我们的目标是递推计算后验密度

$$p(x_t | y_{1:t}), \quad y_{1:t} := (y_1, \dots, y_t).$$

2.1 先看两个朴素例子

如果一上来就看积分式, 读者通常不知道自己到底在算什么。更好的方式, 是先看一个离散例子, 再看一个连续例子。

例 1: 离散状态, 其实就是“把所有旧状态的贡献加起来” 设小车此刻只可能在两个路口: 左路口 L 或右路口 R 。上一时刻后验为

$$\mathbb{P}(x_{t-1} = L | y_{1:t-1}) = 0.7, \quad \mathbb{P}(x_{t-1} = R | y_{1:t-1}) = 0.3.$$

状态转移满足

$$\mathbb{P}(x_t = L | x_{t-1} = L) = 0.8, \quad \mathbb{P}(x_t = L | x_{t-1} = R) = 0.2.$$

那么由附录 [全概率公式](#) 的离散求和版,

$$\mathbb{P}(x_t = L | y_{1:t-1}) = \sum_{x_{t-1} \in \{L, R\}} \mathbb{P}(x_t = L | x_{t-1}) \mathbb{P}(x_{t-1} | y_{1:t-1}),$$

于是

$$\mathbb{P}(x_t = L | y_{1:t-1}) = 0.8 \times 0.7 + 0.2 \times 0.3 = 0.62.$$

这说明预测步并不神秘, 本质上只是把“所有可能的旧状态”都过一遍, 然后把它们对当前状态的贡献加起来。

现在假设传感器在时刻 t 给出观测 y_t , 且似然为

$$\mathbb{P}(y_t | x_t = L) = 0.9, \quad \mathbb{P}(y_t | x_t = R) = 0.2.$$

那么由附录 [Bayes 公式](#),

$$\mathbb{P}(x_t = L | y_{1:t}) \propto \mathbb{P}(y_t | x_t = L) \mathbb{P}(x_t = L | y_{1:t-1}) = 0.9 \times 0.62 = 0.558,$$

$$\mathbb{P}(x_t = R | y_{1:t}) \propto 0.2 \times 0.38 = 0.076.$$

归一化后,

$$\mathbb{P}(x_t = L | y_{1:t}) = \frac{0.558}{0.558 + 0.076} \approx 0.88, \quad \mathbb{P}(x_t = R | y_{1:t}) \approx 0.12.$$

这就是更新步: 先看预测分布, 再用新观测重新分配可信度。

例 2：连续状态，其实就是“把所有旧位置的贡献累加起来” 现在把状态改成连续位置。设上一时刻我们认为小车位置 x_{t-1} 在区间 $[4, 6]$ 上均匀分布，即

$$p(x_{t-1} | y_{1:t-1}) = \begin{cases} \frac{1}{2}, & x_{t-1} \in [4, 6], \\ 0, & \text{其他}. \end{cases}$$

又设运动模型是

$$x_t = x_{t-1} + w_t, \quad w_t \sim \text{Unif}[0, 1],$$

于是转移密度为

$$p(x_t | x_{t-1}) = \begin{cases} 1, & x_t \in [x_{t-1}, x_{t-1} + 1], \\ 0, & \text{其他}. \end{cases}$$

这时若想算预测密度在 $x_t = 6$ 处的值，由附录 [全概率公式](#)，

$$p(x_t = 6 | y_{1:t-1}) = \int_{\mathcal{X}} p(6 | x_{t-1}) p(x_{t-1} | y_{1:t-1}) dx_{t-1}.$$

只有 $x_{t-1} \in [5, 6]$ 时，核 $p(6 | x_{t-1})$ 才不为零，因此

$$p(x_t = 6 | y_{1:t-1}) = \int_5^6 1 \cdot \frac{1}{2} dx_{t-1} = \frac{1}{2}.$$

同理，

$$p(x_t = 4.5 | y_{1:t-1}) = \int_4^{4.5} 1 \cdot \frac{1}{2} dx_{t-1} = \frac{1}{4}.$$

这说明连续情形下，积分并不是额外的神秘操作；它只是把“所有可能的旧位置”对当前点 x_t 的贡献连续地累加起来。收到观测后，再按

$$p(x_t | y_{1:t}) \propto p(y_t | x_t) p(x_t | y_{1:t-1})$$

把靠近观测的位置抬高、把远离观测的位置压低，这就是连续版的更新。

2.2 预测步

由附录 [全概率公式](#)，

$$p(x_t | y_{1:t-1}) = \int_{\mathcal{X}} p(x_t | x_{t-1}) p(x_{t-1} | y_{1:t-1}) dx_{t-1}.$$

这一步把上一时刻的后验经由状态转移核推到当前，称为预测分布。

2.3 更新步

由附录 [Bayes 公式](#)，

$$p(x_t | y_{1:t}) = \frac{p(y_t | x_t) p(x_t | y_{1:t-1})}{p(y_t | y_{1:t-1})}.$$

分母只是归一化常数，因此常写成

$$p(x_t | y_{1:t}) \propto p(y_t | x_t) p(x_t | y_{1:t-1}).$$

合起来，Bayes 滤波就是一条两步递推：

$$\text{预测: } p(x_t | y_{1:t-1}) = \int_{\mathcal{X}} p(x_t | x_{t-1}) p(x_{t-1} | y_{1:t-1}) dx_{t-1},$$

$$\text{更新: } p(x_t | y_{1:t}) \propto p(y_t | x_t) p(x_t | y_{1:t-1}).$$

难点不在公式，而在于这两个分布通常没有解析表达式。粒子滤波就是对这条递推的数值近似。

3 用粒子近似分布

如果你之前没系统学过 π_t^N 、Dirac 质量、经验测度、先验/预测/后验分布这些术语，可以先跳到附录 [术语与记号速查](#)；那一节专门解释这些词到底是什么意思，以及通常在哪些课程里第一次见到。

设一批粒子与权重为

$$\{x_t^{(i)}, w_t^{(i)}\}_{i=1}^N, \quad w_t^{(i)} \geq 0, \quad \sum_{i=1}^N w_t^{(i)} = 1.$$

粒子滤波用经验测度

$$\pi_t^N(dx) = \sum_{i=1}^N w_t^{(i)} \delta_{x_t^{(i)}}(dx)$$

近似目标后验 $\pi_t(dx) = p(x_t | y_{1:t}) dx$ 。这里 $\delta_{x_t^{(i)}}$ 是在粒子位置上的 Dirac 质量。若想先看两个直接可算的“近似后验”例子，可跳到附录 [近似后验的两个朴素例子](#)。

于是对任意测试函数 φ ，其后验期望可用加权和近似：

$$\mathbb{E}[\varphi(x_t) | y_{1:t}] = \int_{\mathcal{X}} \varphi(x) \pi_t(dx) \approx \sum_{i=1}^N w_t^{(i)} \varphi(x_t^{(i)}).$$

特别地，后验均值和二阶矩分别近似为

$$\hat{x}_t \approx \sum_{i=1}^N w_t^{(i)} x_t^{(i)}, \quad \mathbb{E}[x_t x_t^\top | y_{1:t}] \approx \sum_{i=1}^N w_t^{(i)} x_t^{(i)} x_t^{(i)\top}.$$

4 从重要性采样推到权重递推

4.1 静态重要性采样

设目标密度为 $\pi(x)$ ，难以直接采样；提议分布为 $q(x)$ ，容易采样，且 $q(x) > 0$ 在 $\pi(x)$ 的支撑上成立。则

$$\mathbb{E}_\pi[\varphi(x)] = \int_{\mathcal{X}} \varphi(x) \pi(x) dx = \int_{\mathcal{X}} \varphi(x) \frac{\pi(x)}{q(x)} q(x) dx = \mathbb{E}_q[\varphi(x) \omega(x)],$$

其中未归一化重要性权重定义为

$$\omega(x) := \frac{\pi(x)}{q(x)}.$$

若 $x^{(i)} \sim q$, 则自归一化估计为

$$\mathbb{E}_\pi[\varphi(x)] \approx \sum_{i=1}^N \bar{w}^{(i)} \varphi(x^{(i)}), \quad \bar{w}^{(i)} = \frac{\omega(x^{(i)})}{\sum_{j=1}^N \omega(x^{(j)})}.$$

4.2 序贯重要性采样

在滤波问题中, 目标分布随时间变化。设整条状态轨迹为 $x_{0:t}$ 。目标是后验

$$\pi_t(x_{0:t}) := p(x_{0:t} \mid y_{1:t}),$$

而提议分布取作

$$q_t(x_{0:t} \mid y_{1:t}) = q_{t-1}(x_{0:t-1} \mid y_{1:t-1}) q_t(x_t \mid x_{0:t-1}, y_{1:t}).$$

对应的未归一化权重为

$$\omega_t(x_{0:t}) = \frac{\pi_t(x_{0:t})}{q_t(x_{0:t} \mid y_{1:t})}.$$

利用

$$\pi_t(x_{0:t}) \propto p(y_t \mid x_t) p(x_t \mid x_{t-1}) \pi_{t-1}(x_{0:t-1}),$$

可得递推形式

$$\omega_t^{(i)} \propto \omega_{t-1}^{(i)} \frac{p(y_t \mid x_t^{(i)}) p(x_t^{(i)} \mid x_{t-1}^{(i)})}{q_t(x_t^{(i)} \mid x_{0:t-1}^{(i)}, y_{1:t})}.$$

这是序贯重要性采样的核心公式。

4.3 Bootstrap 粒子滤波

若直接选提议分布

$$q_t(x_t \mid x_{0:t-1}, y_{1:t}) = p(x_t \mid x_{t-1}),$$

则上式中的状态转移项约掉, 权重递推大幅简化为

$$\omega_t^{(i)} \propto \omega_{t-1}^{(i)} p(y_t \mid x_t^{(i)}).$$

这就是最经典的 Bootstrap particle filter。它的优点是实现简单; 缺点是没有利用当前观测去设计更聪明的提议分布, 故在观测很尖锐时容易权重退化。

5 重采样：为什么必须做，以及怎么判断何时做

5.1 权重退化

如果长时间只做重要性加权，不做重采样，通常会出现少数粒子拥有几乎全部权重，其余粒子权重接近零。此时虽名义上有 N 个粒子，实际有效样本远小于 N 。

常用诊断量是有效样本数

$$N_{\text{eff}} := \frac{1}{\sum_{i=1}^N (w_t^{(i)})^2}.$$

若所有权重都相等，则 $N_{\text{eff}} = N$ ；若一个粒子独占全部权重，则 $N_{\text{eff}} = 1$ 。

5.2 重采样的数学作用

重采样把带权粒子

$$\{x_t^{(i)}, w_t^{(i)}\}_{i=1}^N$$

转换为等权粒子

$$\{\tilde{x}_t^{(i)}, 1/N\}_{i=1}^N$$

并满足

$$\mathbb{E} \left[\frac{1}{N} \sum_{i=1}^N \varphi(\tilde{x}_t^{(i)}) \mid \{x_t^{(j)}, w_t^{(j)}\}_{j=1}^N \right] = \sum_{j=1}^N w_t^{(j)} \varphi(x_t^{(j)}).$$

也就是说，重采样在条件期望意义下不改变经验测度，但会牺牲多样性并引入额外方差。

5.3 常见选择

最简单的是 multinomial resampling。它直观，但方差偏大。实践中常用 systematic 或 stratified resampling，以降低采样方差。

6 完整算法

Bootstrap 粒子滤波可写成下述步骤：

1. 初始采样： $x_0^{(i)} \sim p(x_0)$ ，令 $w_0^{(i)} = 1/N$ 。

2. 预测：对每个粒子采样

$$x_t^{(i)} \sim p(x_t \mid x_{t-1}^{(i)}).$$

3. 加权：计算未归一化权重

$$\omega_t^{(i)} = w_{t-1}^{(i)} p(y_t \mid x_t^{(i)}),$$

再归一化成 $w_t^{(i)}$ 。

4. 若 $N_{\text{eff}} < N_{\text{thres}}$ ，则重采样并把权重重置为 $1/N$ 。

7 算例一：双峰观测下的权重更新

本节故意选一个一维、离散而短小的例子，用来手算权重。

7.1 模型设定

设当前时刻的预测粒子位置为

$$x_t^{(1)} = -3, \quad x_t^{(2)} = -1, \quad x_t^{(3)} = 1, \quad x_t^{(4)} = 3,$$

预测后它们等权，即 $w_{t|t-1}^{(i)} = 1/4$ 。

观测模型取为

$$y_t = x_t^2 + v_t, \quad v_t \sim \mathcal{N}(0, 1).$$

现在观测到 $y_t = 9$ 。

7.2 逐个计算似然

由高斯似然，

$$p(y_t = 9 | x_t^{(i)}) \propto \exp\left(-\frac{(9 - (x_t^{(i)})^2)^2}{2}\right).$$

四个粒子的平方分别为 9, 1, 1, 9，故未归一化权重与

$$\exp(0), \exp(-32), \exp(-32), \exp(0)$$

成正比。记 $a = \exp(-32) \approx 1.27 \times 10^{-14}$ ，则归一化后

$$w_t^{(1)} = \frac{1}{2 + 2a} \approx \frac{1}{2}, \quad w_t^{(4)} = \frac{1}{2 + 2a} \approx \frac{1}{2},$$

$$w_t^{(2)} = w_t^{(3)} = \frac{a}{2 + 2a} \approx 6.35 \times 10^{-15}.$$

7.3 这组数字说明了什么

更新后，后验几乎完全集中在 -3 与 3 两个粒子上。这个结果非常重要：粒子滤波没有把答案压成 0，而是保留了两个对称峰。若此时用单个高斯去拟合后验，均值会落在 0 附近，但 0 恰好是观测最不支持的位置之一。

7.4 有效样本数

此时

$$N_{\text{eff}} = \frac{1}{2(1/2)^2 + 2(6.35 \times 10^{-15})^2} \approx 2.$$

虽然共有 4 个粒子，但有效样本数约为 2。继续迭代后若退化加重，就应触发重采样。

8 算例二：一维非线性运动的两步递推

上一节只手算了一次更新；这一节写出一个完整的预测-更新-重采样回合。

8.1 模型

取状态模型

$$x_t = \frac{1}{2}x_{t-1} + w_t, \quad w_t \sim \mathcal{N}(0, 1),$$

观测模型

$$y_t = x_t^2 + v_t, \quad v_t \sim \mathcal{N}(0, 1).$$

假设上一时刻重采样后得到四个等权粒子

$$x_{t-1}^{(1)} = -4, \quad x_{t-1}^{(2)} = -2, \quad x_{t-1}^{(3)} = 2, \quad x_{t-1}^{(4)} = 4.$$

8.2 预测

为了算例简单，假设一次实际采样结果恰为

$$x_t^{(1)} = -3, \quad x_t^{(2)} = -1, \quad x_t^{(3)} = 1, \quad x_t^{(4)} = 3.$$

这组值与状态方程是相容的，因为对应噪声样本分别为 $-1, 0, 0, 1$ 。

8.3 更新

若观测仍是 $y_t = 9$ ，则权重就是上一节算出的结果，近似为

$$\left(\frac{1}{2}, 0, 0, \frac{1}{2}\right).$$

8.4 重采样

若做 multinomial resampling，则新粒子会以概率 $1/2$ 从 -3 和 3 中抽取。一次可能的重采样结果为

$$\tilde{x}_t^{(1)} = -3, \quad \tilde{x}_t^{(2)} = -3, \quad \tilde{x}_t^{(3)} = 3, \quad \tilde{x}_t^{(4)} = 3.$$

这说明重采样虽把权重重新拉平，但也明显减少了粒子多样性。这正是后续很多改进方法想要处理的问题。

9 实现时真正要盯的量

9.1 粒子数 N

N 太小时，后验分布会被表示得过于粗糙； N 太大时，计算开销上升。没有万能公式，通常只能依据维度、观测尖锐程度和实时性要求去调。

9.2 提议分布

Bootstrap 方案最简单，但不是最优。若观测很强，应该尝试设计更靠近后验的提议分布，否则权重容易一轮就塌。

9.3 重采样阈值

常见做法是在 $N_{\text{eff}} < N/2$ 或 $N_{\text{eff}} < 0.3N$ 时重采样。阈值过高会导致频繁重采样、样本贫化；阈值过低则权重退化严重。

10 如果只记住几句话

1. 粒子滤波是在近似整条 Bayes 滤波递推，而不是只在做“随机采样”。
2. 它用经验测度去逼近后验，因此天然可以表示多峰和强非线性。
3. 重要性采样给出了权重公式，重采样则是在控制权重退化。
4. 它的根本代价是：表达能力来自大量样本，算力与退化问题永远绕不开。

后续关系 在这份基础笔记之后，粒子滤波还可以与最优输运或神经网络结合。但那是两条不同扩展线，应分别讨论，而不应混在一篇里。

A 术语与记号速查

A.1 这些东西通常在哪些课程里第一次见到

如果按课程来源粗分，大致是这样：

1. 概率论与数理统计：先验、后验、条件概率密度、Bayes 公式。
2. 随机过程或状态估计：状态空间模型、预测分布、滤波递推。
3. 测度论概率或更理论化的概率课：Dirac 质量、测度、经验测度这类写法。
4. Monte Carlo / 统计计算：重要性采样、粒子系统、经验分布近似。

所以如果你之前主要学的是“随机变量 + 密度函数 + 期望”那一套，而没正式学过测度论，那么 $\pi_t^N(dx)$ 这种写法看着陌生是完全正常的。

A.2 π_t 与 π_t^N 到底是什么

这里的 π_t 只是“时刻 t 的目标后验分布”的另一种写法。连续情形下，它对应

$$\pi_t(dx) = p(x_t \mid y_{1:t}) dx.$$

而 π_t^N 表示“用 N 个粒子构造出来的近似分布”：

$$\pi_t^N(dx) = \sum_{i=1}^N w_t^{(i)} \delta_{x_t^{(i)}}(dx).$$

这里上标 N 不是幂次，而是在提醒你：这个对象依赖于粒子数 N 。 N 变大时，通常希望 π_t^N 越来越接近真正的后验 π_t 。

A.3 Dirac 质量是什么

δ_a 表示“把全部质量都压在点 a 上”的分布，也叫 Dirac 质量或点质量。最核心的特征是：对任意测试函数 φ ，都有

$$\int_{\mathcal{X}} \varphi(x) \delta_a(dx) = \varphi(a).$$

如果你暂时不想碰测度论，可以把它粗略理解成：

δ_a 就是在说“这个随机量不散开，它只取点 a ”。

所以

$$\sum_{i=1}^N w_t^{(i)} \delta_{x_t^{(i)}}$$

的意思就是：把权重 $w_t^{(i)}$ 分配给点 $x_t^{(i)}$ ，从而得到一个“由很多带权点组成的分布”。

A.4 经验测度是什么

经验测度这个词听上去抽象，其实只是“把样本云写成分布对象”。

例如，若有三个等权样本

$$2, 5, 9,$$

那么对应的经验测度就是

$$\frac{1}{3}\delta_2 + \frac{1}{3}\delta_5 + \frac{1}{3}\delta_9.$$

它的意义是：以后你要算均值、方差或任意函数的期望时，不必每次都口头说“对三个样本取平均”，而可以统一写成“对经验测度积分”。比如

$$\int_{\mathcal{X}} x \left(\frac{1}{3}\delta_2 + \frac{1}{3}\delta_5 + \frac{1}{3}\delta_9 \right) (dx) = \frac{2+5+9}{3}.$$

因此，粒子滤波里的经验测度不是新物理对象，只是把“粒子 + 权重”这堆东西打包成一个分布。

A.5 先验、预测、后验分别是什么

这三个概念彼此接近，但含义并不相同。

1. 先验：在尚未利用当前观测之前，对状态所持有的分布性认识。
2. 预测分布：把上一时刻后验通过状态转移推到当前时刻后得到的分布，即 $p(x_t | y_{1:t-1})$ 。
3. 后验：融合了当前观测之后的分布，即 $p(x_t | y_{1:t})$ 。

在滤波语境里，可以将三者的关系概括为：

先由上一时刻信息形成预测分布，再结合当前观测完成后验更新。

A.6 为什么正文里要用这些写法

因为粒子滤波的本质不是只计算单个数值，而是在递推整条分布。只要关心的不仅是均值，而是完整的不确定性结构，那么 π_t 、 π_t^N 、 δ_a 这一套写法会比单独书写密度函数更紧凑，也更适合同时处理离散与连续情形。

A.7 近似后验的两个朴素例子

例 1：离散状态时，近似后验就是带权计数 设状态空间只有三个位置

$$\mathcal{X} = \{A, B, C\}.$$

假设真实后验为

$$\pi_t(\{A\}) = 0.1, \quad \pi_t(\{B\}) = 0.3, \quad \pi_t(\{C\}) = 0.6.$$

现在若粒子滤波给出 $N = 5$ 个等权粒子

$$C, C, B, C, A,$$

则经验测度就是

$$\pi_t^5 = \frac{1}{5}\delta_A + \frac{1}{5}\delta_B + \frac{3}{5}\delta_C.$$

这时它对三个状态给出的近似概率分别是

$$\pi_t^5(\{A\}) = \frac{1}{5}, \quad \pi_t^5(\{B\}) = \frac{1}{5}, \quad \pi_t^5(\{C\}) = \frac{3}{5}.$$

它与真实后验

$$(0.1, 0.3, 0.6)$$

并不完全相同，但已经抓住了最主要的结构：状态 C 概率最大，状态 A 最小。这里“近似后验”没有任何神秘之处，本质上就是“看有多少粒子落在各个状态上”。

例 2：连续状态时，近似后验就是带权点去逼近平滑分布 现在设状态是连续位置，真实后验是一条平滑密度曲线，例如大致集中在 $x = 2$ 附近。粒子滤波给出三个带权粒子

$$\begin{aligned} x_t^{(1)} &= 0, & x_t^{(2)} &= 2, & x_t^{(3)} &= 3, \\ w_t^{(1)} &= 0.2, & w_t^{(2)} &= 0.5, & w_t^{(3)} &= 0.3. \end{aligned}$$

那么近似后验写成

$$\pi_t^3(dx) = 0.2 \delta_0(dx) + 0.5 \delta_2(dx) + 0.3 \delta_3(dx).$$

这不表示真实后验真的只在 $0, 2, 3$ 三个点取值，而是表示：

我们暂时只用这三个带权点来代表整条连续后验曲线。

例如，它给出的后验均值近似为

$$\int_{\mathcal{X}} x \pi_t^3(dx) = 0.2 \times 0 + 0.5 \times 2 + 0.3 \times 3 = 1.9.$$

若要近似区间 $[1.5, 3.5]$ 上的后验概率，则只需把落在区间内的粒子权重相加：

$$\pi_t^3([1.5, 3.5]) \approx 0.5 + 0.3 = 0.8.$$

因此，连续情形下所谓“近似后验”，本质上就是：真实对象是一条连续密度曲线，而计算机里我们改用有限个带权点来替代它，并用这些权重去近似均值、区间概率和其他期望量。

B 基础概率公式附录

B.1 全概率公式

设 X 与 Y 具有联合密度 $p(x, y)$ ，其中 $x \in \mathcal{X}$ 。则边缘密度可由条件密度积分得到：

$$p(y) = \int_{\mathcal{X}} p(y | x) p(x) dx.$$

在条件化情形下，如果再给定一个额外信息集 $\mathcal{G}$ ，同样有

$$p(y | \mathcal{G}) = \int_{\mathcal{X}} p(y | x, \mathcal{G}) p(x | \mathcal{G}) dx.$$

粒子滤波预测步正是在 $\mathcal{G} = y_{1:t-1}$ 的条件下，对上式的直接应用。

B.2 Bayes 公式

在同样设定下，若 $p(y) > 0$ ，则后验密度满足

$$p(x | y) = \frac{p(y | x) p(x)}{p(y)}.$$

其中分母也可以借助全概率公式写成

$$p(y) = \int_{\mathcal{X}} p(y | x) p(x) dx.$$

若给定额外信息集 $\mathcal{G}$ ，则条件版 Bayes 公式为

$$p(x | y, \mathcal{G}) = \frac{p(y | x, \mathcal{G}) p(x | \mathcal{G})}{p(y | \mathcal{G})}.$$

粒子滤波更新步对应的是 $\mathcal{G} = y_{1:t-1}$ 的特殊情形。