

粒子滤波基础笔记

从 Bayes 递推到重要性采样、重采样与数值算例

2026 年 3 月 29 日

目录

1	为什么需要粒子滤波	2
2	Bayes 滤波递推：粒子方法要近似的到底是什么	2
2.1	预测步	2
2.2	更新步	3
3	用粒子近似分布	3
4	从重要性采样推到权重递推	3
4.1	静态重要性采样	3
4.2	序贯重要性采样	4
4.3	Bootstrap 粒子滤波	4
5	重采样：为什么必须做，以及怎么判断何时做	5
5.1	权重退化	5
5.2	重采样的数学作用	5
5.3	常见选择	5
6	完整算法	5
7	算例一：双峰观测下的权重更新	6
7.1	模型设定	6
7.2	逐个计算似然	6
7.3	这组数字说明了什么	6
7.4	有效样本数	6

1	为什么需要粒子滤波	2
8	算例二：一维非线性运动的两步递推	7
8.1	模型	7
8.2	预测	7
8.3	更新	7
8.4	重采样	7
9	实现时真正要盯的量	7
9.1	粒子数 N	7
9.2	提议分布	8
9.3	重采样阈值	8
10	如果只记住几句话	8

1 为什么需要粒子滤波

Kalman filter 的核心优势，是把后验分布压缩成均值与协方差。只要系统近似线性、噪声近似高斯，这种压缩几乎不损失关键信息。

但如果后验分布本身不是单峰高斯，这种压缩就会失真。一个典型场景是：状态 x_t 是小车位置，观测却是

$$y_t = x_t^2 + v_t, \quad v_t \sim \mathcal{N}(0, \sigma_y^2).$$

当你测到 $y_t \approx 9$ 时， $x_t \approx 3$ 和 $x_t \approx -3$ 都有可能。后验天然有两个峰，而不是一个峰。此时若仍坚持用单个高斯去近似，就会把两个峰硬压成中间一团。

粒子滤波的基本立场是：既然后验可能很复杂，那就不要强行把它压成一个鼓包，而是直接用一批样本去近似这整个分布。

2 Bayes 滤波递推：粒子方法要近似的到底是什么

考虑状态空间模型

$$x_t \sim p(x_t | x_{t-1}), \quad y_t \sim p(y_t | x_t),$$

其中 $x_t \in \mathbb{R}^d$ 是隐状态， y_t 是观测。我们的目标是递推计算后验密度

$$p(x_t | y_{1:t}), \quad y_{1:t} := (y_1, \dots, y_t).$$

2.1 预测步

由全概率公式，

$$p(x_t | y_{1:t-1}) = \int p(x_t | x_{t-1}) p(x_{t-1} | y_{1:t-1}) dx_{t-1}.$$

这一步把上一时刻的后验经由状态转移核推到当前，称为预测分布。

2.2 更新步

由 Bayes 公式,

$$p(x_t | y_{1:t}) = \frac{p(y_t | x_t) p(x_t | y_{1:t-1})}{p(y_t | y_{1:t-1})}.$$

分母只是归一化常数, 因此常写成

$$p(x_t | y_{1:t}) \propto p(y_t | x_t) p(x_t | y_{1:t-1}).$$

合起来, Bayes 滤波就是一条两步递推:

$$\text{预测: } p(x_t | y_{1:t-1}) = \int p(x_t | x_{t-1}) p(x_{t-1} | y_{1:t-1}) dx_{t-1},$$

$$\text{更新: } p(x_t | y_{1:t}) \propto p(y_t | x_t) p(x_t | y_{1:t-1}).$$

难点不在公式, 而在于这两个分布通常没有解析表达式。粒子滤波就是对这条递推的数值近似。

3 用粒子近似分布

设一批粒子与权重为

$$\{x_t^{(i)}, w_t^{(i)}\}_{i=1}^N, \quad w_t^{(i)} \geq 0, \quad \sum_{i=1}^N w_t^{(i)} = 1.$$

粒子滤波用经验测度

$$\pi_t^N(dx) = \sum_{i=1}^N w_t^{(i)} \delta_{x_t^{(i)}}(dx)$$

近似目标后验 $\pi_t(dx) = p(x_t | y_{1:t}) dx$ 。这里 $\delta_{x_t^{(i)}}$ 是在粒子位置上的 Dirac 质量。

于是对任意测试函数 φ , 其后验期望可用加权和近似:

$$\mathbb{E}[\varphi(x_t) | y_{1:t}] = \int \varphi(x) \pi_t(dx) \approx \sum_{i=1}^N w_t^{(i)} \varphi(x_t^{(i)}).$$

特别地, 后验均值和二阶矩分别近似为

$$\hat{x}_t \approx \sum_{i=1}^N w_t^{(i)} x_t^{(i)}, \quad \mathbb{E}[x_t x_t^\top | y_{1:t}] \approx \sum_{i=1}^N w_t^{(i)} x_t^{(i)} x_t^{(i)\top}.$$

4 从重要性采样推到权重递推

4.1 静态重要性采样

设目标密度为 $\pi(x)$, 难以直接采样; 提议分布为 $q(x)$, 容易采样, 且 $q(x) > 0$ 在 $\pi(x)$ 的支撑上成立。则

$$\mathbb{E}_\pi[\varphi(x)] = \int \varphi(x) \pi(x) dx = \int \varphi(x) \frac{\pi(x)}{q(x)} q(x) dx = \mathbb{E}_q[\varphi(x) \omega(x)],$$

其中未归一化重要性权重定义为

$$\omega(x) := \frac{\pi(x)}{q(x)}.$$

若 $x^{(i)} \sim q$, 则自归一化估计为

$$\mathbb{E}_\pi[\varphi(x)] \approx \sum_{i=1}^N \bar{w}^{(i)} \varphi(x^{(i)}), \quad \bar{w}^{(i)} = \frac{\omega(x^{(i)})}{\sum_{j=1}^N \omega(x^{(j)})}.$$

4.2 序贯重要性采样

在滤波问题中, 目标分布随时间变化。设整条状态轨迹为 $x_{0:t}$ 。目标是后验

$$\pi_t(x_{0:t}) := p(x_{0:t} \mid y_{1:t}),$$

而提议分布取作

$$q_t(x_{0:t} \mid y_{1:t}) = q_{t-1}(x_{0:t-1} \mid y_{1:t-1}) q_t(x_t \mid x_{0:t-1}, y_{1:t}).$$

对应的未归一化权重为

$$\omega_t(x_{0:t}) = \frac{\pi_t(x_{0:t})}{q_t(x_{0:t} \mid y_{1:t})}.$$

利用

$$\pi_t(x_{0:t}) \propto p(y_t \mid x_t) p(x_t \mid x_{t-1}) \pi_{t-1}(x_{0:t-1}),$$

可得递推形式

$$\omega_t^{(i)} \propto \omega_{t-1}^{(i)} \frac{p(y_t \mid x_t^{(i)}) p(x_t^{(i)} \mid x_{t-1}^{(i)})}{q_t(x_t^{(i)} \mid x_{0:t-1}^{(i)}, y_{1:t})}.$$

这是序贯重要性采样的核心公式。

4.3 Bootstrap 粒子滤波

若直接选提议分布

$$q_t(x_t \mid x_{0:t-1}, y_{1:t}) = p(x_t \mid x_{t-1}),$$

则上式中的状态转移项约掉, 权重递推大幅简化为

$$\omega_t^{(i)} \propto \omega_{t-1}^{(i)} p(y_t \mid x_t^{(i)}).$$

这就是最经典的 Bootstrap particle filter。它的优点是实现简单; 缺点是没有利用当前观测去设计更聪明的提议分布, 故在观测很尖锐时容易权重退化。

5 重采样：为什么必须做，以及怎么判断何时做

5.1 权重退化

如果长时间只做重要性加权，不做重采样，通常会出现少数粒子拥有几乎全部权重，其余粒子权重接近零。此时虽名义上有 N 个粒子，实际有效样本远小于 N 。

常用诊断量是有效样本数

$$N_{\text{eff}} := \frac{1}{\sum_{i=1}^N (w_t^{(i)})^2}.$$

若所有权重都相等，则 $N_{\text{eff}} = N$ ；若一个粒子独占全部权重，则 $N_{\text{eff}} = 1$ 。

5.2 重采样的数学作用

重采样把带权粒子

$$\{x_t^{(i)}, w_t^{(i)}\}_{i=1}^N$$

转换为等权粒子

$$\{\tilde{x}_t^{(i)}, 1/N\}_{i=1}^N$$

并满足

$$\mathbb{E} \left[\frac{1}{N} \sum_{i=1}^N \varphi(\tilde{x}_t^{(i)}) \mid \{x_t^{(j)}, w_t^{(j)}\}_{j=1}^N \right] = \sum_{j=1}^N w_t^{(j)} \varphi(x_t^{(j)}).$$

也就是说，重采样在条件期望意义下不改变经验测度，但会牺牲多样性并引入额外方差。

5.3 常见选择

最简单的是 multinomial resampling。它直观，但方差偏大。实践中常用 systematic 或 stratified resampling，以降低采样方差。

6 完整算法

Bootstrap 粒子滤波可写成下述步骤：

1. 初始采样： $x_0^{(i)} \sim p(x_0)$ ，令 $w_0^{(i)} = 1/N$ 。

2. 预测：对每个粒子采样

$$x_t^{(i)} \sim p(x_t \mid x_{t-1}^{(i)}).$$

3. 加权：计算未归一化权重

$$\omega_t^{(i)} = w_{t-1}^{(i)} p(y_t \mid x_t^{(i)}),$$

再归一化成 $w_t^{(i)}$ 。

4. 若 $N_{\text{eff}} < N_{\text{thres}}$ ，则重采样并把权重重置为 $1/N$ 。

7 算例一：双峰观测下的权重更新

本节故意选一个一维、离散而短小的例子，用来手算权重。

7.1 模型设定

设当前时刻的预测粒子位置为

$$x_t^{(1)} = -3, \quad x_t^{(2)} = -1, \quad x_t^{(3)} = 1, \quad x_t^{(4)} = 3,$$

预测后它们等权，即 $w_{t|t-1}^{(i)} = 1/4$ 。

观测模型取为

$$y_t = x_t^2 + v_t, \quad v_t \sim \mathcal{N}(0, 1).$$

现在观测到 $y_t = 9$ 。

7.2 逐个计算似然

由高斯似然，

$$p(y_t = 9 | x_t^{(i)}) \propto \exp\left(-\frac{(9 - (x_t^{(i)})^2)^2}{2}\right).$$

四个粒子的平方分别为 9, 1, 1, 9，故未归一化权重与

$$\exp(0), \exp(-32), \exp(-32), \exp(0)$$

成正比。记 $a = \exp(-32) \approx 1.27 \times 10^{-14}$ ，则归一化后

$$w_t^{(1)} = \frac{1}{2 + 2a} \approx \frac{1}{2}, \quad w_t^{(4)} = \frac{1}{2 + 2a} \approx \frac{1}{2},$$

$$w_t^{(2)} = w_t^{(3)} = \frac{a}{2 + 2a} \approx 6.35 \times 10^{-15}.$$

7.3 这组数字说明了什么

更新后，后验几乎完全集中在 -3 与 3 两个粒子上。这个结果非常重要：粒子滤波没有把答案压成 0，而是保留了两个对称峰。若此时用单个高斯去拟合后验，均值会落在 0 附近，但 0 恰好是观测最不支持的位置之一。

7.4 有效样本数

此时

$$N_{\text{eff}} = \frac{1}{2(1/2)^2 + 2(6.35 \times 10^{-15})^2} \approx 2.$$

虽然共有 4 个粒子，但有效样本数约为 2。继续迭代后若退化加重，就应触发重采样。

8 算例二：一维非线性运动的两步递推

上一节只手算了一次更新；这一节写出一个完整的预测-更新-重采样回合。

8.1 模型

取状态模型

$$x_t = \frac{1}{2}x_{t-1} + w_t, \quad w_t \sim \mathcal{N}(0, 1),$$

观测模型

$$y_t = x_t^2 + v_t, \quad v_t \sim \mathcal{N}(0, 1).$$

假设上一时刻重采样后得到四个等权粒子

$$x_{t-1}^{(1)} = -4, \quad x_{t-1}^{(2)} = -2, \quad x_{t-1}^{(3)} = 2, \quad x_{t-1}^{(4)} = 4.$$

8.2 预测

为了算例简单，假设一次实际采样结果恰为

$$x_t^{(1)} = -3, \quad x_t^{(2)} = -1, \quad x_t^{(3)} = 1, \quad x_t^{(4)} = 3.$$

这组值与状态方程是相容的，因为对应噪声样本分别为 $-1, 0, 0, 1$ 。

8.3 更新

若观测仍是 $y_t = 9$ ，则权重就是上一节算出的结果，近似为

$$\left(\frac{1}{2}, 0, 0, \frac{1}{2}\right).$$

8.4 重采样

若做 multinomial resampling，则新粒子会以概率 $1/2$ 从 -3 和 3 中抽取。一次可能的重采样结果为

$$\tilde{x}_t^{(1)} = -3, \quad \tilde{x}_t^{(2)} = -3, \quad \tilde{x}_t^{(3)} = 3, \quad \tilde{x}_t^{(4)} = 3.$$

这说明重采样虽把权重重新拉平，但也明显减少了粒子多样性。这正是后续很多改进方法想要处理的问题。

9 实现时真正要盯的量

9.1 粒子数 N

N 太小时，后验分布会被表示得过于粗糙； N 太大时，计算开销上升。没有万能公式，通常只能依据维度、观测尖锐程度和实时性要求去调。

9.2 提议分布

Bootstrap 方案最简单，但不是最优。若观测很强，应该尝试设计更靠近后验的提议分布，否则权重容易一轮就塌。

9.3 重采样阈值

常见做法是在 $N_{\text{eff}} < N/2$ 或 $N_{\text{eff}} < 0.3N$ 时重采样。阈值过高会导致频繁重采样、样本贫化；阈值过低则权重退化严重。

10 如果只记住几句话

1. 粒子滤波是在近似整条 Bayes 滤波递推，而不是只在做“随机采样”。
2. 它用经验测度去逼近后验，因此天然可以表示多峰和强非线性。
3. 重要性采样给出了权重公式，重采样则是在控制权重退化。
4. 它的根本代价是：表达能力来自大量样本，算力与退化问题永远绕不开。

后续关系 在这份基础笔记之后，粒子滤波还可以与最优输运或神经网络结合。但那是两条不同扩展线，应分别讨论，而不应混在一篇里。