

粒子滤波与最优输运笔记

从重采样到运输映射

2026 年 3 月 29 日

目录

1	为什么要把最优输运接到粒子滤波上	2
2	把重采样重新表述成一个运输问题	2
2.1	离散耦合矩阵	2
2.2	最优输运目标	2
3	从耦合矩阵到新的等权粒子	3
3.1	ETPF 的线性变换	3
3.2	均值守恒	3
3.3	与随机重采样的本质差别	3
4	一维离散算例：普通重采样与运输式更新	3
4.1	预测粒子与权重	3
4.2	一次随机重采样的结果	3
4.3	构造一个可行运输计划	4
4.4	计算分析粒子	4
4.5	这个算例说明了什么	4
5	与粒子滤波更新的关系	5
5.1	不是替代似然，而是替代重采样	5
5.2	一个更精确的理解	5
6	计算代价与正则化	5
7	总结	5

定位 这份笔记默认你已经知道基础粒子滤波。这里不重写一整篇 PF，只回顾理解最优输运更新所必需的最短背景；不讨论神经网络，也不讨论三者同时混合。

1 为什么要把最优输运接到粒子滤波上

基础粒子滤波在加权之后得到的是带权经验分布

$$\mu^w = \sum_{i=1}^N w_i \delta_{x_i^f}, \quad \sum_{i=1}^N w_i = 1.$$

经典重采样把它重新变成等权样本

$$\mu^{\text{rs}} = \frac{1}{N} \sum_{j=1}^N \delta_{\tilde{x}_j}.$$

问题在于，随机重采样虽然简单，但往往通过复制少数高权粒子完成“去权重化”，因此会带来样本贫化和额外的 Monte Carlo 方差。最优输运方法的目标，是把“去权重化”看成一个运输问题：不再随机复制，而是以最小代价把带权粒子云变成等权粒子云。

2 把重采样重新表述成一个运输问题

2.1 离散耦合矩阵

设预测粒子为 $\{x_i^f\}_{i=1}^N$ ，对应归一化权重 $\{w_i\}_{i=1}^N$ 。我们希望构造分析粒子 $\{x_j^a\}_{j=1}^N$ ，且每个分析粒子都带相同质量 $1/N$ 。

在离散情形下，引入耦合矩阵

$$P = (p_{ij}) \in \mathbb{R}_{\geq 0}^{N \times N},$$

并要求

$$\sum_{j=1}^N p_{ij} = w_i, \quad \sum_{i=1}^N p_{ij} = \frac{1}{N}.$$

第一组约束表示第 i 个预测粒子的质量总共被分配了 w_i ；第二组约束表示每个分析粒子接收的总质量都是 $1/N$ 。

2.2 最优输运目标

若代价函数取平方距离

$$c_{ij} = \|x_i^f - x_j^a\|^2,$$

则离散最优输运问题写成

$$P^* = \arg \min_{P \geq 0} \sum_{i=1}^N \sum_{j=1}^N p_{ij} c_{ij}$$

满足上面的行和、列和约束。

这条式子的含义很直接：把带权经验分布 μ^w 变成等权经验分布时，希望“总搬运路程”尽量短。与随机重采样相比，它给出的是一个结构化的搬运方案。

3 从耦合矩阵到新的等权粒子

3.1 ETPF 的线性变换

在 Ensemble Transform Particle Filter (ETPF) 中, 分析粒子由

$$x_j^a = N \sum_{i=1}^N p_{ij}^* x_i^f$$

给出。由于列和满足 $\sum_i p_{ij}^* = 1/N$, 所以上式是一个凸组合, 因此每个 x_j^a 都位于原粒子凸包之内。

3.2 均值守恒

这个构造有一个重要性质: 分析样本均值等于带权预测均值。证明很短:

$$\frac{1}{N} \sum_{j=1}^N x_j^a = \frac{1}{N} \sum_{j=1}^N \left(N \sum_{i=1}^N p_{ij}^* x_i^f \right) = \sum_{i=1}^N x_i^f \sum_{j=1}^N p_{ij}^* = \sum_{i=1}^N w_i x_i^f.$$

因此 OT 更新不是随意平滑, 而是在保持一阶统计量的同时, 把带权表示改写成等权表示。

3.3 与随机重采样的本质差别

随机重采样产生的是祖先索引, 因此输出样本通常是原粒子的重复拷贝。OT 更新输出的则是原粒子的线性组合, 因此更平滑, 也通常减少额外采样噪声。

4 一维离散算例: 普通重采样与运输式更新

4.1 预测粒子与权重

设一维预测粒子为

$$x^f = (0, 1, 3),$$

权重为

$$w = (0.1, 0.3, 0.6).$$

其带权均值为

$$\sum_{i=1}^3 w_i x_i^f = 0.1 \cdot 0 + 0.3 \cdot 1 + 0.6 \cdot 3 = 2.1.$$

4.2 一次随机重采样的结果

若做一次多项式重采样, 完全可能抽到祖先索引

$$(2, 3, 3),$$

于是得到等权粒子

$$\tilde{x} = (1, 3, 3).$$

这组样本的均值为

$$\frac{1 + 3 + 3}{3} = \frac{7}{3} \approx 2.33,$$

与原带权均值 2.1 已出现偏差。这种偏差不是模型信息，而是重采样本身带来的随机扰动。

4.3 构造一个可行运输计划

现在改用 OT 更新。考虑耦合矩阵

$$P = \begin{bmatrix} 0.1 & 0 & 0 \\ 0.2333 & 0.0667 & 0 \\ 0 & 0.2666 & 0.3334 \end{bmatrix}.$$

它近似满足行和

$$(0.1, 0.3, 0.6)$$

和列和

$$\left(\frac{1}{3}, \frac{1}{3}, \frac{1}{3}\right).$$

4.4 计算分析粒子

按照

$$x_j^a = 3 \sum_{i=1}^3 p_{ij} x_i^f$$

得到

$$x_1^a = 3(0.1 \cdot 0 + 0.2333 \cdot 1 + 0 \cdot 3) \approx 0.70,$$

$$x_2^a = 3(0 \cdot 0 + 0.0667 \cdot 1 + 0.2666 \cdot 3) \approx 2.60,$$

$$x_3^a = 3(0 \cdot 0 + 0 \cdot 1 + 0.3334 \cdot 3) \approx 3.00.$$

于是分析粒子为

$$x^a \approx (0.70, 2.60, 3.00).$$

它们的等权均值是

$$\frac{0.70 + 2.60 + 3.00}{3} = 2.10,$$

与原带权均值完全一致。

4.5 这个算例说明了什么

普通重采样产生的是重复粒子 $(1, 3, 3)$ ，而 OT 更新给出的是平滑搬运后的粒子 $(0.70, 2.60, 3.00)$ 。后者没有凭空丢掉低权粒子携带的信息，而是通过耦合矩阵把这部分质量有组织地搬到了新的等权样本中。

5 与粒子滤波更新的关系

5.1 不是替代似然，而是替代重采样

最优输运方法并没有改掉粒子滤波的贝叶斯更新本质。似然仍然通过权重

$$w_i \propto p(y_t | x_i^f)$$

进入算法。改变的是“如何从带权粒子变回等权粒子”。

5.2 一个更精确的理解

因此 OT 类方法的逻辑是：

1. 预测阶段仍按粒子滤波生成 x_i^f ；
2. 更新阶段先按似然得到权重 w_i ；
3. 然后不做随机复制，而是求运输计划 P^* ；
4. 最后由 P^* 构造新的等权分析粒子 x_j^a 。

6 计算代价与正则化

离散 OT 的主要障碍是计算量。样本数大时，直接求解线性规划会变重。常见做法是加熵正则：

$$\min_{P \geq 0} \sum_{i,j} p_{ij} c_{ij} + \varepsilon \sum_{i,j} p_{ij} (\log p_{ij} - 1),$$

并继续满足行和、列和约束。这样可以用 Sinkhorn 型迭代加速求解。

但要看清代价：你减少了重采样方差，却引入了一个新的优化问题。因此 OT 方法通常适合样本质量比样本数量更关键的场景，而不是任何 PF 都无脑套上去。

7 总结

粒子滤波与最优输运的组合，可以理解成对“重采样”这一步的精细化改造：

1. PF 负责产生带权经验分布；
2. OT 负责把带权分布平滑地变成等权分布；
3. ETPF 则把这一过程写成耦合矩阵与线性变换。

如果只记一句话，那么应当是：

最优输运不是在改变粒子滤波的贝叶斯逻辑，而是在减少“从权重回到样本”这一步的随机损失。