

粒子滤波与神经网络方法笔记

学动力学、学提议分布与学观测特征的三种接法

2026 年 3 月 29 日

目录

1 写在前面：这一篇默认你已经知道什么	2
2 问题从哪里冒出来	2
3 统一视角：网络究竟插在哪个位置	2
4 第一类结合：用网络学动力学残差	3
4.1 基本形式	3
4.2 为什么这有意义	3
4.3 训练方式	3
5 第二类结合：用网络学提议分布	3
5.1 为什么提议分布关键	3
5.2 网络参数化的提议	4
5.3 一个关键解释	4
6 第三类结合：用网络学观测特征	4
6.1 原始观测太复杂时怎么办	4
6.2 它的实质	4
7 一个统一的小车例子	5
7.1 数值设定	5
8 算例一：学习动力学残差前后有什么差别	5
8.1 不用网络残差	5
8.2 加入网络学习的阻滞残差	6
8.3 解释	6

1 写在前面：这一篇默认你已经知道什么	2
9 算例二：学习提议分布如何减少退化	6
9.1 Bootstrap 提议	6
9.2 网络提议	6
10 训练与实现时的注意点	7
10.1 别把网络输出当真理	7
10.2 训练目标要和最终用途对齐	7
10.3 网络会引入额外不稳定性	7
11 如果只记住几句话	7

1 写在前面：这一篇默认你已经知道什么

本笔记默认你已经知道基础粒子滤波的三件事：第一，后验由粒子与权重近似；第二，权重来自重要性采样；第三，重采样是为了解决退化。这里不再重写这些基础，而只讨论神经网络如何嵌入粒子滤波。

本文只谈粒子滤波与神经网络的结合，不讨论最优输运，也不讨论三者同时混合。

2 问题从哪里冒出来

经典粒子滤波的理论框架很清楚，但在真实任务里经常遇到三类困难：

1. 状态转移模型 $p(x_t | x_{t-1})$ 写得不够准。
2. 提议分布 $q(x_t | x_{0:t-1}, y_{1:t})$ 选得太差，导致权重快速退化。
3. 原始观测过于高维，例如图像、波形或点云，直接写观测似然 $p(y_t | x_t)$ 很难。

神经网络并不是来替代 Bayes 递推，而是来替代其中最难手工建模的一部分。

3 统一视角：网络究竟插在哪个位置

粒子滤波的核心递推是

$$\omega_t^{(i)} \propto \omega_{t-1}^{(i)} \frac{p(y_t | x_t^{(i)})p(x_t^{(i)} | x_{t-1}^{(i)})}{q(x_t^{(i)} | x_{0:t-1}^{(i)}, y_{1:t})}.$$

因此网络自然有三种插入点：

1. 用网络参数化状态转移模型 $p_\theta(x_t | x_{t-1}, u_t)$ 。
2. 用网络参数化提议分布 $q_\phi(x_t | x_{t-1}, y_t)$ 。
3. 用网络把原始观测 o_t 编码成低维特征 $z_t = f_\psi(o_t)$ ，再定义 $p(z_t | x_t)$ 。

其中第一类是在学动力学，第二类是在学如何更聪明地采样，第三类是在学观测表征。

4 第一类结合：用网络学动力学残差

4.1 基本形式

设你已有一个粗糙物理模型

$$x_t = f_{\text{phys}}(x_{t-1}, u_t) + w_t.$$

若其系统性偏差明显，可以令网络学习残差项 r_θ ，写成

$$x_t = f_{\text{phys}}(x_{t-1}, u_t) + r_\theta(x_{t-1}, u_t) + w_t.$$

于是转移密度写为

$$p_\theta(x_t | x_{t-1}, u_t) = \mathcal{N}(f_{\text{phys}}(x_{t-1}, u_t) + r_\theta(x_{t-1}, u_t), Q).$$

4.2 为什么这有意义

这样做保留了物理先验的骨架，只把难写准的偏差交给网络。与纯黑盒模型相比，它更容易训练，也更容易解释。

4.3 训练方式

若离线数据里有状态对 (x_{t-1}, x_t) ，可直接最小化负对数似然

$$\mathcal{L}(\theta) = \sum_t \frac{1}{2} \left(x_t - f_{\text{phys}}(x_{t-1}, u_t) - r_\theta(x_{t-1}, u_t) \right)^\top Q^{-1} \left(x_t - f_{\text{phys}}(x_{t-1}, u_t) - r_\theta(x_{t-1}, u_t) \right) + \text{const.}$$

若 $Q = \sigma^2 I$ ，这退化为加权平方误差。

5 第二类结合：用网络学提议分布

5.1 为什么提议分布关键

基础粒子滤波常用 Bootstrap 提议

$$q(x_t | x_{t-1}, y_t) = p(x_t | x_{t-1}),$$

它完全忽略当前观测 y_t 。如果观测很尖锐，采出的粒子大多会落在后验低概率区，于是权重退化严重。

5.2 网络参数化的提议

一种更聪明的做法是直接令

$$q_\phi(x_t | x_{t-1}, y_t) = \mathcal{N}(\mu_\phi(x_{t-1}, y_t), \Sigma_\phi(x_{t-1}, y_t)),$$

其中 μ_ϕ, Σ_ϕ 由网络输出。此时粒子采样变为

$$x_t^{(i)} \sim q_\phi(\cdot | x_{t-1}^{(i)}, y_t).$$

对应权重递推为

$$\omega_t^{(i)} \propto \omega_{t-1}^{(i)} \frac{p(y_t | x_t^{(i)}) p_\theta(x_t^{(i)} | x_{t-1}^{(i)})}{q_\phi(x_t^{(i)} | x_{t-1}^{(i)}, y_t)}.$$

5.3 一个关键解释

网络提议并不是把 Bayes 公式改掉，而是在改变“你从哪里采样”。只要权重按上式校正，理论上目标后验仍然不变。网络的价值，是让更多粒子落在真正重要的区域，从而提高样本效率。

6 第三类结合：用网络学观测特征

6.1 原始观测太复杂时怎么办

设传感器给出的不是简单标量 y_t ，而是高维原始观测 o_t ，例如图像。直接写 $p(o_t | x_t)$ 往往不现实。

一种常见做法是先通过编码器 f_ψ 得到低维特征

$$z_t = f_\psi(o_t),$$

再用较简单的似然模型

$$p(z_t | x_t) = \mathcal{N}(h(x_t), R).$$

于是权重更新变成

$$\omega_t^{(i)} \propto \omega_{t-1}^{(i)} p(z_t | x_t^{(i)}).$$

6.2 它的实质

这等于把“复杂感知问题”与“状态估计问题”拆开处理。网络先把图像变成适合滤波的表征，粒子滤波再负责不确定性传播与多峰后验表示。

7 一个统一的小车例子

考虑一维小车位置 x_t 与控制输入 u_t 。粗糙物理模型写成

$$x_t = x_{t-1} + u_t + w_t, \quad w_t \sim \mathcal{N}(0, 1).$$

但在湿滑路面上，车辆会系统性少走一点，真实模型更接近

$$x_t = x_{t-1} + u_t - 0.4u_t + w_t.$$

如果物理模型没有这项阻滞偏差，粒子会整体偏右。

7.1 数值设定

设 $u_t = 2$ ，上一时刻有三个等权粒子

$$x_{t-1}^{(1)} = 4, \quad x_{t-1}^{(2)} = 5, \quad x_{t-1}^{(3)} = 6.$$

现有观测来自摄像头编码器，输出一个近似位置特征 $z_t = 6.2$ ，且

$$p(z_t | x_t) = \mathcal{N}(x_t, 0.25).$$

8 算例一：学习动力学残差前后有什么差别

8.1 不用网络残差

若直接用粗糙模型 $x_t = x_{t-1} + 2 + w_t$ ，忽略噪声均值，只看预测中心，则三个预测中心为

$$6, 7, 8.$$

对观测 $z_t = 6.2$ 的似然与

$$\exp\left(-\frac{(6.2-6)^2}{2 \times 0.25}\right), \exp\left(-\frac{(6.2-7)^2}{2 \times 0.25}\right), \exp\left(-\frac{(6.2-8)^2}{2 \times 0.25}\right)$$

成正比，即

$$\exp(-0.08), \exp(-1.28), \exp(-6.48).$$

约为

$$0.923, 0.278, 0.0015.$$

归一化后权重约为

$$0.768, 0.231, 0.001.$$

8.2 加入网络学习的阻滞残差

设网络已学到残差 $r_\theta(x_{t-1}, u_t) \approx -0.8$ ，则预测中心改为

$$5.2, 6.2, 7.2.$$

此时似然与

$$\exp(-2), \exp(0), \exp(-2)$$

成正比，约为

$$0.135, 1, 0.135.$$

归一化后权重约为

$$0.107, 0.787, 0.107.$$

8.3 解释

没有网络残差时，粒子整体偏右，只有最左边粒子勉强贴近观测；加入残差后，中间粒子恰好与观测对齐，后验结构更合理。这说明网络不是在替代滤波，而是在修正错误的动力学先验。

9 算例二：学习提议分布如何减少退化

9.1 Bootstrap 提议

仍用上一节设定。若基础提议只根据动力学采样，可能产生三个新粒子

$$6.8, 7.5, 8.1.$$

对 $z_t = 6.2$ 的似然将急剧衰减，因此大部分权重集中到 6.8 那个粒子上， N_{eff} 很小。

9.2 网络提议

若网络输出

$$q_\phi(x_t | x_{t-1}, z_t) = \mathcal{N}(6.2, 0.25),$$

则采样更可能落在 6 到 6.5 附近。例如一次采样得到

$$6.0, 6.2, 6.4.$$

它们对观测的似然都不低，归一化后的权重会更加均匀。即便还需用

$$\omega_t^{(i)} \propto \omega_{t-1}^{(i)} \frac{p(z_t | x_t^{(i)}) p_\theta(x_t^{(i)} | x_{t-1}^{(i)})}{q_\phi(x_t^{(i)} | x_{t-1}^{(i)}, z_t)}$$

做严格校正，退化程度通常仍显著减轻。

10 训练与实现时的注意点

10.1 别把网络输出当真理

网络转移模型、网络提议和网络观测编码都只是模型的一部分。只要它们与真实分布有偏差，粒子滤波就必须继续用权重校正和重采样来维持后验一致性。

10.2 训练目标要和最终用途对齐

学动力学残差时，可用一步预测误差或负对数似然。学提议分布时，更合理的目标往往不是简单回归，而是让提议分布更贴近真实后验，从而减小权重方差。学观测编码时，则要确保编码保留与状态估计有关的信息。

10.3 网络会引入额外不稳定性

如果训练分布与部署分布相差太大，网络学到的模型很容易失效。此时粒子滤波虽然还能工作，但权重退化可能比纯物理模型更糟。

11 如果只记住几句话

1. 网络最常见的三种插入点是：动力学、提议分布、观测特征。
2. 它提升的是模型能力或采样效率，而不是取消 Bayes 校正。
3. 学动力学残差适合“物理骨架基本对，但细节有系统偏差”的情形。
4. 学提议分布适合“观测很强，Bootstrap 提议太浪费粒子”的情形。
5. 学观测特征适合“观测原始维度太高，似然难手写”的情形。